出处：*Survey on Knowledge Distillation for Large Language Models: Methods, Evaluation, and Application*（Chuanpeng Yang 等，2024），arXiv:2407.01885，https://arxiv.org/abs/2407.01885 。本译本依据 arXiv v1（2024 年 7 月 2 日）版本译出；图不翻译，仅以一句话说明图的内容；参考文献保留英文原文并按原文编号列出。标有「译者注」的内容为译者所加，非原文。

大语言模型知识蒸馏综述：方法、评估与应用

CHUANPENG YANG，中国科学院信息工程研究所 & 中国科学院大学网络空间安全学院，中国
WANG LU*，清华大学，中国
YAO ZHU*，浙江大学，中国
YIDONG WANG，北京大学，中国
QIAN CHEN，中国科学院计算技术研究所，中国科学院大学，中国
CHENLONG GAO，中国科学院计算技术研究所，中国
BINGJIE YAN，中国科学院计算技术研究所，中国科学院大学，中国
YIQIANG CHEN，中国科学院计算技术研究所，中国

大语言模型（Large Language Models, LLMs）已在各个领域展现出卓越的能力，吸引了学术界和工业界的极大兴趣。尽管其性能令人印象深刻，但 LLM 庞大的规模和计算需求给实际部署带来了相当大的挑战，尤其是在资源有限的环境中。在保持准确率的同时压缩语言模型，已成为研究的焦点。在各种方法中，知识蒸馏（knowledge distillation）已成为一种在不大幅牺牲性能的前提下提升推理速度的有效技术。本文从方法、评估和应用三个方面进行了全面综述，探讨专门为 LLM 定制的知识蒸馏技术。具体而言，我们把方法分为白盒 KD（white-box KD）和黑盒 KD（black-box KD），以更好地说明它们之间的差异。此外，我们还探讨了不同蒸馏方法之间的评估任务和蒸馏效果，并提出了未来的研究方向。通过深入了解最新进展和实际应用，本综述为研究者提供了宝贵的资源，为该领域的持续进步铺平道路。

CCS 概念（CCS Concepts）： • 计算方法 → 自然语言处理；• 通用与参考 → 综述与概览。

其他关键词和短语： 知识蒸馏，大语言模型，评估

* 通讯作者：Wang Lu 和 Yao Zhu。

作者地址：Chuanpeng Yang，中国科学院信息工程研究所 & 中国科学院大学网络空间安全学院，中国北京，yangchuanpeng@iie.ac.cn；Wang Lu，清华大学，中国，newlw230630@gmail.com；Yao Zhu，浙江大学，中国，ee_zhuy@zju.edu.cn；Yidong Wang，北京大学，中国北京市海淀区，yidongwang37@gmail.com；Qian Chen，中国科学院计算技术研究所，中国科学院大学，中国，chenqian20b@ict.ac.cn；Chenlong Gao，中国科学院计算技术研究所，中国，gaochenlong@ict.ac.cn；Bingjie Yan，中国科学院计算技术研究所，中国科学院大学，中国，bj.yan@ieee.org；Yiqiang Chen，中国科学院计算技术研究所，中国，yqchen@ict.ac.cn。

（版权声明，原文模板文字）允许个人或课堂使用而免费制作本作品全部或部分内容的数字或纸质副本，前提是副本不得为营利或商业利益而制作或分发，且副本须在首页载有本声明及完整引用。由作者以外他人拥有版权的部分必须予以尊重。允许注明出处的摘录。以其他方式复制、再版、发布到服务器或分发到列表，需要事先获得特定许可和/或支付费用。请向 permissions@acm.org 申请许可。© 2018 版权归所有者/作者所有。出版权授予 ACM。ACM 2157-6904/2018/8-ART28。https://doi.org/XXXXXXX.XXXXXXX

译者注：该 arXiv 版本使用的是 ACM 期刊模板的占位信息（年份 2018、卷号、DOI 均为模板默认值），并非真实出版信息。

ACM 引用格式： Chuanpeng Yang, Wang Lu, Yao Zhu, Yidong Wang, Qian Chen, Chenlong Gao, Bingjie Yan, and Yiqiang Chen. 2018. Survey on Knowledge Distillation for Large Language Models: Methods,

Evaluation, and Application. ACM Trans. Intell. Syst. Technol. 37, 4, Article 28 (August 2018), 28 pages. https://doi.org/XXXXXXX.XXXXXXX

图 1（图不翻译）：本综述的总体分类框架图，从“方法”“评估”“应用”三方面组织 LLM 知识蒸馏的相关工作。原图注：本综述的总体分类框架。

1 引言（Introduction）

大语言模型（LLM）[2, 17, 130, 146, 166] 的出现显著提升了各类生成任务中的文本生成质量，成为人工智能领域一个关键且被广泛讨论的话题。与前代模型相比，这些模型对未见过的数据表现出更强的泛化能力。此外，它们还展现出小模型所不具备的能力，如多步推理 [47, 69, 83] 和指令遵循 [103, 144, 154]。LLM 的成功通常归功于训练数据的增加和模型参数量的增大（例如，GPT-3 拥有 1750 亿参数 [12]）。然而，参数规模的扩张也带来了显著的弊端，尤其是推理成本高昂和内存需求巨大，使实际部署面临挑战。例如，GPT-3 需要约 350GB 的模型存储（float16），推理时至少需要 5 块各有 80GB 显存的 A100 GPU，这也大大增加了碳排放。为了缓解这些挑战，模型压缩（model compression）[30, 40] 已成为一种可行的解决方案。模型压缩旨在把大型、资源密集的模型转换为更紧凑的版本，使其适合存储在受限的移动设备上。这一过程可能涉及为降低延迟而进行优化以实现更快的执行，或在最小延迟与模型性能之间取得平衡。因此，把这些高容量模型应用于真实场景的一个关键目标是压缩它们，在尽可能保持性能的同时减少参数数量。

随着降低计算资源需求变得日益关键，知识蒸馏（Knowledge Distillation, KD）[43] 成为一种很有前景的技术。KD 是一种机器学习方法，专注于通过把知识从一个大型复杂模型迁移到一个更小、更高效的模型来压缩和加速模型。这一技术常被用于把存储在大型深度神经网络模型中的知识浓缩到较小的模型中，从而在不显著牺牲性能的前提下降低计算资源需求并提升推理速度。从根本上说，知识蒸馏利用大模型在大规模数据集上获得的丰富知识来指导小模型的训练。这些知识通常包括大模型的输出概率分布、中间层表示和损失函数。在训练过程中，小模型不仅要匹配原始数据标签，还要模仿大模型的行为。对于只能通过 API 访问的先进模型（如 GPT-4 [2]），其生成的指令和解释可以帮助训练学生模型 [54]。

随着知识蒸馏的最新进展，已有若干研究对各种蒸馏技术的最新进展进行了总结。具体而言，Gou 等人 [37] 对知识蒸馏进行了全面的综述，涉及六个关键方面：知识类别、训练方案、师生架构、蒸馏算法、性能比较和应用。类似地，Wang 等人 [141] 全面总结了与视觉任务相关的知识蒸馏技术的研究进展和技术细节。Alkhulaifi 等人 [4] 提出了一种称为蒸馏度量（distillation metric）的创新指标，并用它来评估不同的知识压缩方法。此外，Hu 等人 [48] 探讨了跨多种蒸馏目标的各种师生架构，介绍了不同的知识表示及其相应的优化目标。他们还系统地概述了师生架构，纳入了代表性的学习算法和有效的蒸馏方案。

现有的知识蒸馏综述奠定了重要基础，并为模型压缩提供了宝贵见解 [13, 51, 64]。然而，LLM 的出现给 KD 带来了若干新挑战：1）大语言模型并非为文本生成这样的单一任务而设计，而是追求在各种任务和未见数据上的广泛通用性，包括涌现能力。因此，评估压缩后 LLM 的泛化能力需要细致而全面的评估。2）现有综述只是对已有工作的总结，并未提供把 KD 技术应用于在真实场景中压缩和部署 LLM 的具体案例。这种案例研究可以帮助读者为不同规模的 LLM 选择最佳的 KD 方案。

为了应对这些挑战，人们已经开发了多种专门为 LLM 设计的知识蒸馏算法。本文旨在为这些方法提供一份全面而有见地的指南。本综述的总体分类框架如图 1 所示，它从方法、评估和应用三个方面考察 LLM 的蒸馏算法。为了清晰地解释这些方法，我们把它们分为白盒 KD 和黑盒 KD。白盒 KD 包括两种不同类型：基于 logits 的方法（Logits-based methods）[43]，在 logits 层面迁移知识；以及基于提示（hint）的方法（Hint-based methods）[109]，通过中间特征传递知识。黑盒 KD 是一种基于 API 的方法，只能获取教师模型的输出。这一类通常包括三种方法：上下文学习（In-Context Learning）[52]、思维链（Chain-of-Thought）[69] 和指令遵循（Instruction Following）[144]。此外，我们还在鲁棒性基准 [94, 128, 138] 上同时评估了上述两类蒸馏算法的有效性。最后，我们讨论了不同蒸馏方法之间的关系和应用场景，并提出了未来的研究方向。

本文其余部分组织如下。第 2 节简要回顾知识蒸馏方法的定义。接着，第 3 节深入探讨 LLM 领域中的蒸馏方法和评估方法。第 4 节介绍应用，第 5 节总结知识蒸馏面临的挑战并探讨未来研究方向。最后，第 6 节总结全文。

2 知识蒸馏概述（Overview of Knowledge Distillation）

在本节中，我们总结了每种知识蒸馏算法的优化目标。

2.1 基于 Logits 的 KD（Logits-based KD）

顾名思义，基于 logit 的 KD [43] 是一种利用教师模型中的 logit 进行知识迁移的蒸馏范式。我们可以把一般的知识蒸馏损失函数表述如下:

$$\mathcal{L}_{\text{logits}} = \mathrm{KL}\left(p^t \,\|\, p^s\right) = \sum_{j=1}^{C} p_j^t \log \frac{p_j^t}{p_j^s}, \tag{1}$$

$$p_i^s = \frac{\exp\left(z_i^s/\tau\right)}{\sum_{j=1}^{C} \exp\left(z_j^s/\tau\right)}, \qquad p_i^t = \frac{\exp\left(z_i^t/\tau\right)}{\sum_{j=1}^{C} \exp\left(z_j^t/\tau\right)}, \tag{2}$$

其中 $z^s, z^t \in \mathbb{R}^C$ 分别表示学生网络和教师网络输出的 logits。τ 是温度参数，用于调节 logits 的平滑程度。C 表示类别数。Kullback-Leibler 散度（KLD）[43] 损失也可以替换为其他函数，例如反向 Kullback–Leibler（Reverse KL, RKL）[20, 53, 65, 96] 蒸馏、Jensen–Shannon（JS）[129] 蒸馏等。

> 译者注：原文中把“logits-based”有时误写作“logic-based”，此处按原意译为“基于 logits”。式（2）教师分布分母的下标在原 PDF 中写作 z_i^t，按常规 softmax 记法应为 z_j^t，译文按常规写法给出。logits 就是 softmax 之前的原始打分；温度 τ 越大，概率分布越“平”，越能体现教师对各类别之间相似性的判断。

2.2 基于提示的 KD（Hint-based KD）

由于在基于 logit 的知识蒸馏中学生提取知识的能力有限，研究者们力求更精确地复制教师的行为。因此，人们提出了基于中间特征的知识蒸馏 [46, 122]。这种技术是让学生模型与教师模型的中间层输出相匹配。这种方法要求学生既理解结果，也理解得出这些结果的过程。基于特征的知识蒸馏损失函数的一般形式如下:

$$\mathcal{L}_{\text{hint}} = \mathcal{H}\left(F^s, F^t\right) = \left\|F^t - \phi\left(F^s\right)\right\|^2, \tag{3}$$

其中 $F^s, F^t \in \mathbb{R}^{H\times W\times C}$ 分别表示学生网络和教师网络的中间特征。函数 ϕ 用于确保学生特征与教师特征的维度一致。度量函数用 $\mathcal{H}$ 表示，作为示例，我们使用均方误差。

2.3 上下文学习（In-Context Learning）

ICL [12, 52] 使用由任务描述或若干任务样例作为示例组成的自然语言提示。形式化地，令 $D_K = \{f(x_1, y_1), \ldots, f(x_k, y_k)\}$ 表示一组 k 个样例，其中 $f(x_k, y_k)$ 是把第 k 个任务样例转换为自然语言提示的

函数。给定任务描述 I、示例集 D_k 和一个新的输入查询 x_{k+1}，LLM 生成的预测输出 $\hat{y}_{k+1}$ 可以用如下公式描述：

$$\text{LLM}\Big(I,\ \underbrace{f(x_1,y_1),\ldots,f(x_k,y_k)}_{\text{示例 (demonstrations)}},\ f(\ \underbrace{x_{k+1}}_{\text{输入 (input)}}\ ,\ \underbrace{\quad}_{\text{答案 (answer)}}\ )\Big) \rightarrow \hat{y}_{k+1}, \tag{4}$$

其中答案 y_{k+1} 留空，由 LLM 来预测。学生模型被用来预测 LLM 生成的结果。

2.4 思维链（Chain-of-Thought）

CoT [47, 69, 83, 136] 把中间推理步骤整合进提示中，而不是像 ICL 那样仅依赖简单的输入-输出对。

$$\text{LLM}\Big(I,\ \underbrace{f(x_1,r_1,y_1),\ldots,f(x_k,r_k,y_k)}_{\text{示例 (demonstrations)}},\ f(\ \underbrace{x_{k+1}}_{\text{输入 (input)}}\ ,\ \underbrace{\quad}_{\text{推理依据 (rationale)}}\ ,\ \underbrace{\quad}_{\text{答案 (answer)}}\ )\Big) \rightarrow \hat{r}_{k+1},\hat{y}_{k+1}. \tag{5}$$

其中 r_k 表示用户提供的推理依据（rationale），用来解释为什么 x_k 的答案是 y_k。此时，学生模型不仅需要预测教师模型的标签，还需要模仿教师生成的理由。

2.5 指令遵循（Instruction Following）

通过在用自然语言描述的结构化多任务数据集上进行微调, LLM 在同样以指令格式表达的未见任务上表现出熟练的能力 [98, 112, 149]。通过指令微调（instruction tuning），LLM 能够在无需显式示例的情况下按照任务说明完成新任务，从而提升其泛化能力。蒸馏指令遵循技能的过程包括：用 LLM 生成特定任务的指令，然后用这个指令数据集微调学生模型。

3 大语言模型中的知识蒸馏（Knowledge Distillation in Large Language Models）

Transformer 架构具有很高的可扩展性，使得构建拥有数十亿甚至数万亿参数的超大模型成为可能。它支撑着 NLP、CV 和多模态领域中许多最著名的大规模模型。例如，GPT 系列 [2, 12]、LLaMA [130] 和 Qwen [7] 等著名大语言模型都基于其仅解码器（decoder-only）配置。2023 年之前，关于基于 Transformer 的 NLP 蒸馏研究 [111, 126] 主要围绕 BERT 架构展开。然而，随着预训练大语言模型的兴起 [2, 98]，人们越来越关注对拥有十亿级参数的 Transformer 进行蒸馏，以及为数据有限、计算成本高的场景开发更高效的蒸馏方法 [44, 47]。现有的蒸馏算法主要分为两类：白盒 KD 和黑盒 KD。

3.1 白盒知识蒸馏（White-box Knowledge Distillation）

白盒蒸馏依赖于在训练中需要访问教师模型内部数据的方法，利用教师模型可获取的内部信息。在下面的讨论中，我们探讨两种不同类型的白盒知识蒸馏。首先是 Hinton 等人 [43] 提出的基于 logits 的方法，它在 logits 层面迁移知识，即用教师模型的 logits 来传递知识。鉴于学生在基于 logits 的知识蒸馏中获得的知识有限，研究者们希望更准确地复制教师的行为。为此，Romero 等人 [109] 提出了基于提示的知识蒸馏，即对齐学生模型与教师模型中间层的特征输出。这种方法要求学生不仅理解最终结果，还要理解得出这些结果的过程。在下面

的小节中，我们从评估任务的角度详细分析每种方法的特点（如表 1 所示）。此外，我们还基于鲁棒性评估两类蒸馏算法的优缺点，为算法的适用场景提供一定的指导。

3.1.1 基于 Logits 的 KD（Logits-based KD） 对双向长短期记忆网络（BiLSTM）的蒸馏 [126] 标志着把知识蒸馏应用于 BERT [60] 的最早尝试。其蒸馏目标是最小化学生网络 logits 与教师网络 logits 之间的均方误差损失。该方法在三项任务上进行了测试：句子分类和句子匹配。实验结果表明，基于浅层 BiLSTM 的模型取得了与 ELMo 语言模型 [104] 相当的性能，但参数量少约 100 倍，推理速度提高 15 倍。类似地，DistillBERT [111] 用教师的参数初始化一个较浅的学生模型，并最小化教师与学生之间软目标概率的差异，这种技术称为词级知识蒸馏（word-level knowledge distillation）。它引入了一种三重损失（triple loss），结合语言建模损失、蒸馏损失和余弦距离损失，以利用预训练模型学到的归纳偏置。DistilBERT 在九项任务上取得了与 ELMo 基线相当或更优的性能。与 BERT 相比，DistilBERT 在参数量减少 40% 的同时保持了 97% 的性能。

译者注：原文写“三项任务”，但随后只列出了句子分类和句子匹配两类，此处按原文照译。

表 1：大语言模型上代表性白盒 KD 方法的比较。压缩率（compression ratio）表示原始未压缩模型规模与压缩后模型规模之比。

模型	蒸馏类型	教师模型	压缩率	评估任务	与教师模型的比较
DistillBiLSTM [126]	基于 logits	BERT_base	114×	GLUE[137]: SST-2/QQP/MNLI-m/MNLI-mm	81.1/87.7（92% 性能）
DistillBERT [111]	基于 logits	BERT_base	2×	GLUE[137]: SST-2/QQP/MNLI/QNLI/RTE/MRPC/CoLA/STS-B/WNLI	77.0/79.5（97% 性能）
MixKD [75]	基于 logits	BERT_base	2×	GLUE[137]: SST-2/QQP/MNLI-m/MNLI-mm/QNLI/RTE/MRPC	77.2/82.6（93% 性能）
ReAugKD [163]	基于 logits	BERT_base	2×	GLUE[137]: SST-2/QQP/QNLI/RTE/MRPC/CoLA	81.8/82.3（99% 性能）
PD [134]	基于 logits	BERT_base	2×	GLUE[137]: SST-2/QQP/MNLI/QNLI/RTE/MRPC	82.1/81.7（100.5% 性能）
MINILLM [38]	基于 logits	GPT-2_1.5B	12×	Dolly[38]/SelfInst[142]/Vicuna[24]/S-NI[145]/UnNI[45]	22.0~25.5 / 24.5（91%~106% 性能）
MINILLM [38]	基于 logits	OPT_13B	10×	同上	24.3~26.9 / 29.4（92%~102% 性能）
MINILLM [38]	基于 logits	LLaMA_13B	2×	同上	29.7 / 29.4（101% 性能）
GKD [3]	基于 logits	T5_XL	39×	XSum[93]/WMT14EN-DE[10]/GSM8K[27]/MMLU[41]/BBH[119]	14.5/26.0（56% 性能）
MiniMA [161]	基于 logits	LLaMA-2_7B	2×	MMLU[41]/CEval[132]/BBH[119]/GSM8K[27]/HumanEval[21]	31.1/28.3（76% 性能）
PKD [122]	基于提示（hint）	BERT_base	2×	GLUE[137]: SST-2/QQP/MNLI-m/MNLI-mm/QNLI/RTE/MRPC	77.7/84.9（92% 性能）
MetaDistil [168]	基于提示	BERT_base	2×	GLUE[137]: SST-2/QQP/MNLI/QNLI/RTE/MRPC/CoLA/STS-B	80.4/80.7（99% 性能）
AD-KD [155]	基于提示	BERT_base	2×	GLUE[137]: SST-2/QQP/MNLI/QNLI/RTE/MRPC/CoLA/STS-B	83.4/84.1（99% 性能）

模型	蒸馏类型	教师模型	压缩率	评估任务	与教师模型的比较
XtremeDistil [91]	基于提示	mBERT_base	35×	Multilingual NER[100]/IMDB[82]/SST-2[117]/Elec[85]/DbPedia[165]/AG News[165]	88.6/92.7（95% 性能）
TinyBERT [55]	基于提示	BERT_base	7×	GLUE[137]: SST-2/QQP/MNLI-m/MNLI-mm/QNLI/RTE/MRPC/CoLA/STS-B	77.0/79.5（97% 性能）
MobileBERT [123]	基于提示	IB-BERT_large	4×	GLUE[137]: SST-2/QQP/MNLI-m/MNLI-mm/QNLI/RTE/MRPC/CoLA/STS-B	77.7/78.3（99% 性能）
MiniLM [143]	基于提示	BERT_base	2×	SQuAD2[106]/ GLUE[137]: SST-2/MNLI-m	80.4/81.5（99% 性能）
TED [74]	基于提示	DeBERTaV3_base	2×	GLUE[137]: SST-2/QQP/MNLI-m/MNLI-mm/QNLI/RTE/MRPC/CoLA/STS-B	87.5/88.9（98% 性能）
HomoDistil [73]	基于提示	BERT_base	7×	GLUE[137]: SST-2/QQP/MNLI/QNLI/RTE/MRPC/CoLA/STS-B	79.0/84.6（93% 性能）

译者注：“与教师模型的比较”一列的格式为“学生得分/教师得分（学生达到教师性能的百分比）”。

MixKD [75] 通过对样例对进行线性插值，扩展了鼓励学生模仿教师 logits 的思路。它利用数据增强，从现有的特定任务数据中创造额外样本，从而提升知识蒸馏的效果。这种方法就像学生通过进一步提问来深入探究教师的答案和概念，从而更有效地向教师学习，为学生模型从大规模语言模型中汲取洞见提供了更多数据。在六个数据集上的评估结果表明，MixKD 在压缩大语言模型方面显著优于传统知识蒸馏及以往方法。ReAugKD [163] 包含推理阶段和训练阶段。在推理阶段，它聚合由教师生成、且与学生嵌入高度相似的软标签。在训练阶段，它使用一种新颖的关系型 KD 损失（relationship KD loss）来最小化师生嵌入及其分布之间的差异。在六个数据集上的评估结果表明，ReAugKD 取得了优于基线的性能，而延迟开销不到基线的 3%，凸显了整合检索信息能够显著提升泛化能力。Turc 等人 [134] 提出了一种预训练蒸馏（pre-training distillation, PD）方法，这是一种通用而简单的构建紧凑模型的算法。它由三个标准训练操作序列组成，可应用于任何架构选择。该方法还探讨了用传统的基于 logits 的 KD 从大型微调模型迁移任务知识，并在六个数据集上评估了其性能。平均而言，这种预训练蒸馏方法表现最好，甚至超过了相应的教师模型。上述蒸馏算法都以 BERT 作为教师模型、以 GLUE 作为评估基准。随着模型规模的增大，现有的蒸馏算法和评估标准已无法满足要求。

MINILLM [38] 针对传统基于 logits 的知识蒸馏方法的局限，提出了一种把大语言模型（LLM）蒸馏成较小模型的创新方法，重点在于自由生成（free-running generation）过程中最小化前向 Kullback-Leibler 散度。该方法把标准 KD 方法的前向 KLD 目标替换为反向 KLD，后者更适合在语言模型上进行生成式 KD，旨在防止学生模型高估教师分布中的低概率部分。

> 译者注：原文此处先说“focusing on minimizing the forward Kullback-Leibler divergence”，紧接着又说用反向 KLD 替换前向 KLD，前后有出入；MiniLLM 原论文的核心是最小化**反向** KLD，前一句应为笔误。

为了进一步稳定并加速训练，该方法引入了一种有效的优化方法，包括三个关键步骤：1）单步分解（single-step

decomposition）以降低方差；2）教师混合采样（teacher mixed sampling）以缓解奖励投机（reward hacking）；3）长度归一化（length normalization）以抵消长度偏差。MINILLM 被应用于参数规模从 1.2 亿到 130 亿不等的模型。在五个数据集上使用 Rouge-L [77]、人工评判和 GPT-4 反馈进行的实验评估一致表明，该方法优于标准 KD 基线。进一步的研究和分析表明，MINILLM 可以减少暴露偏差（exposure bias）并提升长回答的生成性能。

与 MINILLM 类似，GKD [3] 不再只依赖一组固定的输出序列，而是训练学生模型生成自己的序列，并由教师模型提供反馈。与监督式 KD 方法不同，GKD 允许在学生与教师之间使用其他损失函数，这在学生模型缺乏有效模仿教师分布的表达能力时很有优势。此外，GKD 使蒸馏与语言模型的强化学习（RL）微调能够无缝结合。通过提供优化反向 KL 和广义 JSD 等其他散度度量的灵活性，GKD 让容量有限的学生能够专注于生成与教师监督下产生的样本相似的样本。研究表明，在策略（on-policy）GKD 便于把蒸馏与语言模型的 RL [98] 微调结合起来，而这种组合此前尚未被探索过。在对初始学生的性能提升方面，在不同规模的 T5 学生模型上，GKD 平均在摘要任务上带来 2.1 倍、在机器翻译任务上带来 1.7 倍、在算术推理任务上带来 1.9 倍的相对增益，凸显了 GKD 的有效性。在对初始学生的性能提升方面，GKD 在各种规模的 T5 学生模型上，于摘要任务平均取得 2.1 倍、机器翻译任务 1.7 倍、算术推理任务 1.9 倍的相对增益，突出了 GKD 的有效性。

> 译者注：上一段最后两句在原文中内容重复，译文照原文保留。原文“abstracts”此处指摘要（summarization）任务。

Wen 等人 [151] 提出了 f-DISTILL 框架，通过最小化广义 f-散度函数来表述序列级知识蒸馏。该框架引入了四种蒸馏变体，并证明现有的 SeqKD [63] 和 ENGINE [132] 方法分别是 KL 蒸馏和反向 KL 蒸馏的近似。此外，f-DISTILL 方法还包含逐步分解（step-wise decomposition），把复杂的序列级散度转换为更易处理的词级损失，便于计算。该方法在四个数据集上进行了评估：用于数据到文本生成的 DART [92]、用于摘要的 XSum [93]、用于机器翻译的 WMT16 EN-RO [11]，以及 Commonsense Dialogue [167]。实验表明，f-DISTILL 的各个变体优于现有的分布匹配型 KD 方法，并且在与表示匹配型 KD 方法结合时能带来性能提升。此外，结果表明对称的蒸馏损失优于非对称的蒸馏损失，证实了极端的众数平均（mode averaging）或众数坍缩（mode collapse）都不是最优的。MiniMA [161] 发现，当学生模型约为教师模型规模的 40% 时，蒸馏效果最佳。它把结构化剪枝与基于 logit 的知识蒸馏结合起来，以 LLaMA2-7B [130] 作为教师模型训练出 3B 的 MiniMA 模型。结果表明，MiniMA 在知识、推理和编码（encoding）方面取得了令人印象深刻的性能，而所用的 token 数量与教师模型相近甚至更少。

3.1.2 基于提示的 KD（Hint-based KD） 基于特征的知识蒸馏方法 [46, 122] 从嵌入空间、Transformer 层和预测层中提取知识，使学生模型能够全面学习教师模型的各个方面。例如，Sun 等人 [122] 提出了一种耐心知识蒸馏（patient knowledge distillation, PKD）方法，旨在把大规模教师模型压缩成一个同样有效的轻量级学生模型。他们提出了两种不同的蒸馏策略：1）PKD-Last：学生模型从教师模型的最后 k 层学习，其假设是顶层包含信息量最大的知识；2）PKD-Skip：学生每隔 k 层从教师的一层学习，这意味着较低层也包含应在蒸馏过程中逐步迁移的重要信息。在四类任务（情感分类、复述相似度匹配、自然语言推断和机器阅读理解）的七个数据集上进行的实验表明，PKD 方法优于标准知识蒸馏方法。它取得了更优的性能和更好的泛化能力，在保持与原始大规模模型相当准确率的同时，显著提升了训练效率并降低了存储需求。MetaDistill [168] 在训练过程中保持教师模型固定，为传统 KD 方法提供了一种简单高效的替代方案。在元学习框架内，教师网络通过蒸馏关于学生表现的反馈来增强向学生网络的知识迁移。此外，它还引入了一种试探性更新（pilot update）机制，以改善内部学习器与元学习器之间的对齐，重点提升内部学习器的性能。大量实验验证了该方法在文本和图像分类任务上的有效性和通用性。此外，在 GLUE 基准上的实验表明，MetaDistill 显著优于传统知识蒸馏，实现了最先进的压缩性能。AD-KD [155] 针对现有知识蒸馏方法的两个关键局限：其一，学生模型往往只是模仿教师的行为，而没有发展出自己的推理能力；其二，这些方法通常侧重迁移特定于复杂模型的知识，而忽略了特定于数据的知识。为了克服这些问题，AD-KD 提出了一种创新的归因驱动（attribution-driven）知识蒸馏方法，使用基于梯度的归因方法 [124] 计算每个输入 token 的重要性分数。为了尽量减少教师输入嵌入中不太重要的维度的影响，它采用 top-K 策略过滤掉归因分数较低的维度。剩余的分数被聚合并归一化，以反映各个

token 的重要性。此外，该方法提取所有潜在预测的归因知识，而不仅仅是概率最高的预测。为了改进推理与泛化方面的知识迁移，AD-KD 探索了对教师所有潜在决策的多视角归因蒸馏。在 GLUE 基准上的实验结果表明，该方法的性能超过了若干最先进的方法。

Mukherjee 等人 [91] 提出了 XtremeDistil，这是一种利用与教师架构无关的内部表示和参数投影的蒸馏方法。与以往聚焦单语 GLUE 任务的方法不同，该方法以多语言双向 Transformer 编码器表示（mBERT）[131] 作为教师模型，对涵盖 41 种语言的多语言命名实体识别（NER）进行蒸馏。实验结果表明，XtremeDistil 实现了更高的压缩率和更快的推理速度。此外，该研究还探讨了蒸馏中若干此前未被考察的方面，包括无标注迁移数据和标注资源的影响、多语言词嵌入的选择、架构修改以及推理延迟。该方法把教师模型的参数量压缩了最多 35 倍，并把批量推理延迟降低了 51 倍，同时在大规模多语言 NER 上保持了 95% 的性能，在分类任务上则持平甚至超过教师。TinyBERT [55] 把预训练蒸馏与微调蒸馏结合起来，从 BERT 中同时捕获通用领域知识和特定任务知识。它从不同层中提取多种类型的知识，包括嵌入层、隐藏状态、注意力矩阵和变换层。在 GLUE 基准评估中，它达到了其教师模型 BERT_base 96.8% 以上的性能，同时推理速度快 7.5 到 9.4 倍。

> 译者注：原文此句字面意思是“其教师模型 BERT_base 取得了超过 96.8% 的性能”，结合 TinyBERT 原论文，应理解为 TinyBERT 达到了教师 BERT_base 96.8% 以上的性能，译文按此意译出。

MiniLM [143] 为任务无关的基于 Transformer 的语言模型（LM）蒸馏提出了一种深度自注意力蒸馏（deep self-attention distillation）框架。该方法单独取出教师模型最后一个 Transformer 层的自注意力模块，并把该模块中值（value）之间的缩放点积作为一种新形式的深度自注意力知识。这一技术把两个模型不同维度的表示都转换为维度匹配的关系矩阵，无需额外参数来变换学生表示，从而解决了教师与学生模型之间的层对齐难题。这增强了学生模型在深度上的灵活性。MiniLM 只用教师模型 50% 的 Transformer 参数和计算资源，就在 SQuAD 2.0 [106] 和多项 GLUE 基准任务上保持了 99% 以上的准确率。这证明了在蒸馏大型预训练 Transformer 模型时引入教师助理（teacher assistant）[90] 的有效性。TED [74] 提出了一种创新的任务感知逐层（原文作 layout）蒸馏方法，旨在解决学生模型的欠拟合问题，并去除教师隐藏表示中的不必要信息。该方法在每一层对齐学生和教师的隐藏表示，并采用任务感知过滤器提取与目标任务相关的知识。这样做缩小了模型之间的知识差距，增强了学生适应目标任务的能力。MobileBERT [123] 和 HomoBERT [73] 主要关注在保持模型深度的同时调整其宽度。这与 Turc 等人 [134] 的发现形成对比，他们发现改变模型深度会显著影响性能。MobileBERT 在教师和学生模型中都引入了瓶颈（bottleneck）和倒瓶颈（inverted bottleneck）结构来修改隐藏维度。然而，这种做法可能破坏多头注意力与前馈网络之间的参数平衡，这一问题通过堆叠前馈网络（stacked FFN）的方法得到缓解。随后，通过 Transformer 层的注意力和隐藏状态进行知识提取。另一方面，HomoBERT 采用了剪枝。它首先用教师模型初始化学生模型，以确保初始差异最小。然后，它针对输入嵌入、隐藏状态、注意力矩阵和输出 logits 进行剪枝，并构建蒸馏损失函数。在每次迭代中，根据重要性分数剪掉最重要（原文如此）的神经元，并用蒸馏损失训练学生模型。这一迭代过程持续进行，直到学生模型达到期望的规模。虽然白盒蒸馏受限于 LLM 的专有性质，适用范围受到限制，但 Alpaca [127] 和 Vicuna [24] 等多种开源 LLM 的兴起为白盒蒸馏的未来带来了可观的前景。

> 译者注：MiniLM 原论文中蒸馏的是自注意力分布以及值（value）之间的关系；HomoBERT 原论文是按重要性分数剪掉“最不重要”的神经元，原文此处写作“most significant”，疑为笔误，译文保留原文意思并加注。

3.2 白盒 KD 的鲁棒性评估（Robustness Evaluation of White-box KD）

现有白盒 KD 算法的评估标准多种多样，其中大多数以 BERT 作为教师模型。然而，这些蒸馏算法在 LLM 语境下的有效性仍不清楚。在 [139] 工作的基础上，我们从鲁棒性的角度对这些算法进行了统一评估，具体关注对抗鲁棒性（adversarial robustness）和分布外（out-of-distribution, OOD）鲁棒性。这两类鲁棒性都与输入受到扰动时的性能有关，这对安全敏感的应用尤为关键。对抗鲁棒性考察模型面对对抗性的、难以察觉的扰动时

的稳定性，而 OOD 鲁棒性评估模型在与训练数据分布不同的未见数据上的表现。为了评估对抗鲁棒性，我们采用 AdvGLUE [138] 和 ANLI [95] 基准，以攻击成功率（Attack Success Rate, ASR）作为指标。对于 OOD 鲁棒性，我们使用 Flipkart [135] 评论数据集和 DDXPlus [128] 医疗诊断数据集，以 F1 分数（F1）作为指标。受 MINILLM [38] 工作的启发，我们使用 Dolly[1] 数据集进行蒸馏，对学生模型和教师模型都进行微调。我们同时评估了五种蒸馏算法和四种模型的鲁棒性。

脚注 1：https://github.com/databrickslabs/dolly/tree/master

评估结果见表 2–4。首先，我们观察到 MINILLM 在 GPT-2 上展现出更优的整体蒸馏性能。值得注意的是，对于 3.4 亿参数的 GPT-2，与其他四种蒸馏算法相比，它在对抗数据集和分布外数据集上都取得了最先进的结果。此外，对于任何规模的 GPT-2，MINILLM 在 Flipkart 和 DDXPlus 数据集上都优于其他算法，凸显了其对分布外数据出色的泛化能力。其次，对于 OPT 模型，我们发现最直接的 KD 算法——在每个 token 步上以教师分布作为监督来微调学生模型——取得了最佳的整体性能。同样，在 Flipkart 数据集上，对于任何规模的 OPT，MINILLM 都优于其他蒸馏算法，甚至超过了教师模型。最后，对于 LLaMA，SeqKD 表现出相对更好的蒸馏效果，而对于 LLaMA2，JS 表现相对更优。这表明，即使模型规模相同、结构相似，同一蒸馏算法的效果也可能差异很大。

译者注：ASR（攻击成功率）越低说明模型越鲁棒（↓ 表示越低越好）；F1 越高越好（↑）。表中 SST-2 至 ANLI 七列为对抗鲁棒性（ASR↓），Flipkart、DDXPlus 两列为分布外鲁棒性（F1↑）。粗体与 * 标记按原表保留。

表 2：GPT-2 的评估结果。每个模型规模的最优分数以粗体显示，学生模型超过教师的分数以 * 标记。

参数量（Params）	方法（Method）	SST-2	QQP	MNLI	QNLI	RTE	MNLI-MM	ANLI	Flipkart	DDXPlus
1.5B	教师（Teacher）	54.73	96.15	86.78	93.92	80.25	87.65	87.67	38.55	0.40
120M	SFT	57.43	96.15	91.74	86.49	61.73	88.89	96.17	14.26	0
120M	KD	83.78	**94.87***	89.26	92.57	69.14	**82.72***	94.08	12.96	0
120M	SeqKD	70.27	96.15	90.08	87.84	75.31	83.95	**88.83**	12.61	0
120M	RKL	66.89	98.72	**87.60**	85.81	65.43	93.83	98.08	7.46	0
120M	JS	**54.05***	100	94.21	**77.70***	74.07	95.06	97.83	20.25	0
120M	MINILLM	64.19	100	89.26	90.54	**53.09***	84.57	95.50	**23.32**	**1.25***
340M	SFT	70.27	97.44	92.56	95.27	**55.56***	83.33	94.00	46.36	0
340M	KD	63.51	98.72	84.30	90.54	72.84	80.86	92.42	52.12	0
340M	SeqKD	66.89	97.44	81.82	93.24	72.84	79.01	97.08	47.87	0
340M	RKL	62.16	96.15	95.04	95.27	70.37	92.59	96.92	33.64	0
340M	JS	62.16	96.15	95.04	95.27	70.37	92.59	96.92	32.29	0
340M	MINILLM	**54.73***	**92.31***	**78.51***	**87.16***	69.14	**75.31***	**88.75**	**52.45***	**0.68***
760M	SFT	56.76	97.44	90.91	92.57	80.25	91.36	91.75	28.52	0
760M	KD	**53.38***	**94.87***	90.91	95.27	64.20	87.65	95.58	30.77	0
760M	SeqKD	55.41	96.15	90.91	97.30	80.25	89.51	94.17	27.60	0
760M	RKL	64.86	97.44	90.91	92.57	85.19	95.06	98.67	20.53	0
760M	JS	60.14	98.72	95.04	94.59	77.78	96.30	98.58	19.90	0
760M	MINILLM	54.05	96.15	**81.82***	**89.19***	**60.49***	**72.22***	**85.33***	**47.00***	0

表 3：OPT 的评估结果。

参数量（Params）	方法（Method）	SST-2	QQP	MNLI	QNLI	RTE	MNLI-MM	ANLI	Flipkart	DDXPlus
13B	教师（Teacher）	52.70	94.87	76.03	91.89	61.73	70.99	99.58	54.81	0.18
1.3B	SFT	54.05	94.87	78.51	94.59	61.73	77.78	98.00	51.06	**1.84***
1.3B	KD	52.03	**65.38***	**77.69**	**68.92***	50.62	**69.14***	87.67	44.45	0
1.3B	SeqKD	48.65	93.59	80.17	85.14	83.95	75.31	**78.17***	28.85	0.30
1.3B	RKL	**45.95***	94.87	92.56	97.30	74.07	90.12	99.00	46.41	0
1.3B	JS	47.97	82.05	80.99	89.86	48.15	89.51	94.67	45.15	0
1.3B	MINILLM	47.30	94.87	78.51	79.73	**49.38***	71.60	89.75	**55.88***	0.13
2.7B	SFT	51.35	96.15	92.56	97.30	69.14	93.83	98.17	47.86	0
2.7B	KD	**44.59***	84.62	**73.55***	83.78	64.20	**66.05***	**70.67***	41.83	0
2.7B	SeqKD	47.97	**75.64***	77.69	**77.03***	**61.73**	72.22	88.50	34.85	0
2.7B	RKL	56.08	98.72	90.91	99.32	100	95.68	96.83	53.01	**0.29***
2.7B	JS	67.57	96.15	86.78	97.97	75.31	89.51	92.25	46.55	0
2.7B	MINILLM	47.30	94.87	**73.55***	91.89	66.67	72.84	81.17	**58.09***	0.09
6.7B	SFT	49.32	89.74	85.12	81.76	77.78	79.63	**75.58***	43.05	0.06
6.7B	KD	**45.27***	94.87	80.17	85.14	58.02	**73.46**	81.33	50.99	0
6.7B	SeqKD	50.68	92.31	85.95	77.70	86.42	80.86	78.17	32.01	**0.65***
6.7B	RKL	60.81	91.03	95.87	88.51	**49.38***	93.21	97.92	24.16	0
6.7B	JS	63.51	**88.46***	94.21	**69.59***	62.96	88.27	98.58	26.05	0
6.7B	MINILLM	50.68	92.31	**74.38***	95.27	80.25	75.93	86.75	**56.43***	0

表 4：LLaMA 与 LLaMA2 的评估结果。

参数量（Params）	方法（Method）	SST-2	QQP	MNLI	QNLI	RTE	MNLI-MM	ANLI	Flipkart	DDXPlus
13B（LLaMA 教师）	教师（Teacher）	41.89	65.38	76.03	52.70	56.79	64.20	66.42	56.01	9.09
LLaMA_7B	SFT	47.97	67.95	71.90	48.65	46.91	66.67	67.33	52.65	2.81
LLaMA_7B	KD	43.24	60.26	73.55	54.73	56.79	**64.20**	**66.58**	**65.16***	4.32
LLaMA_7B	SeqKD	**40.54***	65.38	**67.77***	49.32	**41.98***	64.81	66.67	56.58	**5.66**
LLaMA_7B	RKL	**40.54***	76.92	72.73	**45.27***	50.62	64.81	67.75	52.74	0.43
LLaMA_7B	JS	43.92	66.67	73.55	52.70	56.79	**64.20**	67.00	57.35	3.44
LLaMA_7B	MINILLM	42.57	**48.72***	71.90	51.35	56.79	64.81	66.92	52.27	5.21
13B（LLaMA2 教师）	教师（Teacher）	54.05	47.44	65.29	51.35	46.91	62.96	71.00	29.76	0
LLaMA2_7B	SFT	**43.92***	69.23	75.21	63.51	61.73	66.05	69.92	50.76	0.17
LLaMA2_7B	KD	47.97	70.51	74.38	52.70	56.79	64.20	83.67	55.51	1.75
LLaMA2_7B	SeqKD	49.32	66.67	75.21	52.70	56.79	63.59	84.50	**55.63***	1.67
LLaMA2_7B	RKL	52.03	61.54	**73.55**	**47.97***	58.02	**63.58**	72.33	55.42	4.37
LLaMA2_7B	JS	51.35	**57.69**	78.51	56.76	**37.04***	66.67	**69.00***	50.38	**12.19***
LLaMA2_7B	MINILLM	50.00	75.64	75.21	58.78	48.15	69.75	83.67	31.94	0

3.3 关于白盒 KD 的讨论（Discussion on White-box KD）

基于 logits 的 KD 方法通常侧重于对齐教师模型与学生模型之间的输出分布。相比之下，基于提示的 KD 方法可以通过对齐中间层来传递更丰富的信息，从而取得更好的效果。然而，实现逐层的知识蒸馏需要仔细设计教师与学生模型之间的层映射，并需要对模型架构有深入的理解。基于 logits 和基于提示的 KD 方法在蒸馏过程中都需要大量 GPU 显存。尽管教师网络不需要反向传播，但前向传播过程中中间特征的激活值仍会消耗大量 GPU 显存。因此，探索降低训练成本、缩短训练时间的方法至关重要。

3.4 黑盒知识蒸馏（Black-box Knowledge Distillation）

前面讨论的两种蒸馏技术都依赖于访问教师模型的内部数据，因此被归为白盒蒸馏方法，它们在训练时需要内部数据。然而，许多现代大规模闭源模型并不提供内部数据的访问权限，使我们只能使用模型的预测结果。仅通过教师模型的预测来迁移知识的蒸馏被称为黑盒知识蒸馏。研究者发现，当模型参数足够大时，模型会展现出显著的多面性，使其能够处理复杂任务。许多黑盒蒸馏方法利用了这种能力，通常使用三种技术：上下文学习、思维链和指令遵循。在本节中，我们根据对涌现能力的利用方式进一步对黑盒 KD 方法进行分类。

表 5：大语言模型上代表性黑盒 KD 方法的比较。

模型	蒸馏类型	教师模型	压缩率	评估任务	与教师模型的比较
ILD [52]	ICL	BERT_large	13×	LAMA[105]	52.4/57.3（91% 性能）
ILD [52]	ICL	GPT-2_large	6×	CrossFit[159]	61.2/66.2（92% 性能）
LLM-R [140]	ICL	LLaMA_13B	2×	Commonsense/Coreference/Paraphrase/Sentiment/Data-to-text/Summarize/etc.(30)	68.8/67.5（107% 性能）
MT-CoT [75]	CoT	GPT-3_text-davinci-002	58×	CommonsenseQA[125]/StrategyQA[35]/OpenbookQA[87]	30.5/32.1（98% 性能）
Distilling step-by-step [47]	CoT	PaLM_540B	2455×	e-SNLI[14]/ANLI[95]/CQA[125]/SVAMP[102]	58.4/72.3（81% 性能）
Fine-tune-CoT [44]	CoT	InstructGPT 175B_text-davinci-002	26×	SingleEq/AddSub/MultiArith/GSM8K/AQUA-RAT/SVAMP/StrategyQA/etc.(12)	42.2/65.5（64% 性能）
MCC-KD [19]	CoT	GPT-3.5_Turbo	/	GSM8K[27]/ASDiv[86]/SVAMP[102]/CommonsenseQA[1	66.3/75.1（87% 性能）
SCOTT [142]	CoT	GPT-neox_20B	7×	CSQA[125]/CREAK[37]/ESNLI[14]/StrategyQA[35]	67.0/73.3（91% 性能）
LTD [56]	CoT	Codex_code-davinci-002	29×	SVAMP[102]/GSM8K[27]/MathQA[5]	42.5/58.8（72% 性能）
PaD [170]	CoT	PaLM_60B	78×	SVAMP[102]/GSM8K[27]/ASDiv[86]/MultiArith[110]/BBH	42.5/58.8（98% 性能）
Learn-to-Reason [16]	CoT	ChatGPT_175B	29×	GSM8K[27]/MultiArith[110]/SVAMP[102]/CSQA[125]/Str	62.1/76.5（82% 性能）
LaMini-LM [154]	IF	Alpaca_7B	9×	Multiple-Choice QA/Extractive QA/Sentiment Analysis/Paraphrase Identification/etc.(15)	60.8/62.3（98% 性能）
Lion [54]	IF	ChatGPT_175B	25×	BBH[119]	32.0/48.9（65% 性能）

模型	蒸馏类型	教师模型	压缩率	评估任务	与教师模型的比较
UniNER [169]	IF	GPT-3.5_turbo-0301	/	UNIVERSAL NER BENCHMARK [169]	41.7/34.9（119% 性能）

译者注: 表中 ICL 为上下文学习, CoT 为思维链, IF 为指令遵循（Instruction Following）;“etc.(30)”等表示共 30 个等任务。

3.4.1 上下文学习（In-Context Learning） ICL 最初在 GPT-3 [12] 中被提出，它使用一个同时包含任务描述和多个任务样例作为示例的自然语言提示。这一过程从任务描述开始，然后从任务数据集中选择特定实例作为样例。接着，用预定义的模板把这些实例格式化为自然语言提示，并按特定顺序排列。最后，把测试样本加入 LLM 的输入以产生输出。

在这一概念的基础上，Huang 等人 [52] 提出了上下文学习蒸馏（In-Context Learning Distillation），旨在通过上下文学习和语言建模目标有效地提取和迁移知识，从而增强多任务模型的少样本学习能力。该方法引入了两种少样本学习范式：元上下文微调（Meta In-context Tuning）和多任务上下文微调（Multitask In-context Tuning）。在 Meta-ICT [22, 88] 中，语言模型使用上下文学习目标在广泛的任务上进行元训练，随后通过上下文学习适应未见的目标任务。然而，上下文学习的效果在很大程度上依赖于预训练期间积累的知识 [108]，这可能限制它充分利用训练数据中提供的“输入-标签”对应关系 [89]。为了解决这一局限，人们提出了另一种称为多任务上下文微调的少样本学习范式。Meta-ICT 使学生模型能够通过上下文学习和教师指导来适应新任务，而 Multitask-ICT 则把所有目标任务都视为训练任务，并直接使用这些任务中的样例进行上下文学习蒸馏。这两种少样本学习范式需要在性能和计算效率之间进行权衡。在分类、自然语言推断和问答等任务上的结果表明，Multitask-ICT 在把模型规模缩小 93% 的同时保留了教师 91.4% 的性能。因此，Multitask-ICT 被证明更有效，尽管计算成本更高。LLM-R [140] 利用一个预训练且参数冻结的 LLM 检索高质量的上下文样例，然后对其排序以生成训练数据。随后，它使用交叉编码器（cross-encoder）构建一个奖励模型来捕捉排序偏好。最后，应用知识蒸馏训练一个基于双编码器（dual encoders）的稠密检索器。我们（原文如此，指 LLM-R 的作者）在多种任务上对 LLM-R 进行的全面评估一致表明，它优于若干强基线。此外，该模型在不同任务规模和 LLM 架构上都表现出可扩展性。详细分析表明，该方法使上下文学习性能平均提升 7.8%，并且在各种规模的 LLM 上都观察到一致的提升。

译者注：原文本段后半部分使用“Our comprehensive evaluation…”“our model”等第一人称表述，似直接沿用了 LLM-R 原论文的措辞，译文加注说明。

3.4.2 思维链（Chain-of-Thought） 思维链（CoT）[47, 69, 83, 136] 是一种高级提示策略，旨在增强 LLM 处理复杂推理任务的能力。与 ICL 用输入-输出对来构造提示的方式不同，CoT 在提示中融入了包含最终输出的中间推理步骤。通常，CoT 蒸馏 [16, 19, 44, 56, 59, 68, 69, 116, 142, 147, 170] 是利用大规模模型构建聚焦于推理任务的丰富数据集，再用这些数据集微调学生模型。因此，其主要关注点在于为训练生成高质量的推理依据（rationale），并确保学生能有效利用这些推理依据 [47, 59, 69, 116, 142]。

Li 等人 [69] 率先使用 LLM 生成的解释来增强较小推理模型的训练。他们系统地探索了从 LLM 中获取解释的三种方法，并将其整合进一个多任务学习框架，使紧凑模型具备强大的推理和解释能力。在多项推理任务上，实验一致表明他们的方法在各种条件下都优于基线微调方法。值得注意的是，在 Commonsense QA 上经过 60 轮微调后，它比 GPT-3（175B）的准确率最多高出 9.5%。他们的方法生成的高质量解释阐明了 AI 可解释预测背后的理由。Hsieh 等人 [47] 提出了逐步蒸馏（Distilling step-by-step），这是一种新颖而简单的方法，旨在减少把 LLM 提炼、微调为较小模型所需的训练数据量。其方法的核心是一种范式转变：LLM 不仅仅是噪声标签的来源，而是能够提供自然语言推理来证明其预测合理性的代理。在四个 NLP 基准测试上的实证结果得出了三项值得注意的结论。第一，与微调和传统蒸馏方法相比，他们的模型把所需的平均训练样本数减少了 50% 以

上（某些情况下减少超过 85%），并带来了更好的性能。第二，他们的模型在规模显著更小的情况下取得了优于 LLM 的性能，从而降低了部署所需的计算资源。第三，他们的方法同时减少了模型规模和所需数据，却仍能超越 LLM。例如，他们最终版本的 770M T5 模型仅用 80% 的标注数据集，就超过了一个 5400 亿参数 LLM 的性能。

此外，Ho 等人 [44] 提出了微调 CoT（fine-tuning CoT），这是一种利用 LLM 的推理能力来指导较小模型解决复杂任务的方法。通过随机采样从教师模型生成多种推理解答，他们丰富了学生模型的训练数据。使用广泛可得的模型在 12 项任务上的评估表明，微调 CoT 使较小模型获得了显著的推理性能，同时保留了基于提示的 CoT 推理的大部分通用性，而这种推理以前依赖于参数超过 1000 亿的模型。因此，参数少至 3 亿的模型在特定任务上也能胜过更大的模型，甚至超过拥有 1750 亿参数的教师模型。类似地，Chen 等人 [19] 提出了多 CoT 一致性知识蒸馏（Multi-CoT Consistent Knowledge Distillation, MCC-KD），以高效地捕获推理能力的多样性和一致性。在 MCC-KD 中，为每个问题生成多个基本推理依据（原文为 fundamental principles），并通过最小化答案分布之间的双向 KL 散度来加强相应预测之间的一致性。MCC-KD 的有效性在多种模型架构上的数学推理和常识推理基准上得到评估。实证结果不仅证实了 MCC-KD 在分布内数据集上的优越性能，还凸显了其在分布外数据集上强大的泛化能力。Fu 等人 [34] 应用 CoT 让较小的语言模型专精于多步数学推理任务。Shridhar 等人 [116] 详细介绍的 SOCRATIC CoT 方法把原问题分解为一系列子问题，并使用一对紧凑的蒸馏模型: 一个问题分解器和一个子问题求解器。这两个模型协作分解并求解新任务中出现的复杂问题。在 GSM8K、StrategyQA 和 SVAMP 等多个推理数据集上的评估表明，这种蒸馏方法使较小模型的性能比基线提升了 70% 以上。另一方面，SCOTT [142] 提出了一条核心原则：利用 LLM 通过对比解码（contrastive decoding，原文作 comparative decoding）引导出正确答案。该方法鼓励教师模型生成与正确答案高度一致的 token，从而提高蒸馏过程的忠实度。Jie 等人 [56] 和 Zhu 等人 [170] 通过程序蒸馏（program distillation）增强了数学推理能力。Chae 等人 [16] 和 Wang 等人 [147] 提出了一种交互式多轮循环学习框架。在该框架中，前者侧重于用多跳推理训练学生，后者则让学生主动把自己的学习状态告知 LLM 教师；随后，教师针对学生的反馈提供定制化的解释，引导他们反思自己的错误。

译者注：原文“Fu et al.[34] Fu et al.[34]”有重复，译文只保留一次。

3.4.3 指令遵循（Instruction Following） 指令遵循能力旨在增强语言模型在不过度依赖有限样例的情况下执行新任务的能力。通过在由指令指定的各种任务上进行微调，语言模型展现出准确执行以前未见过的指令所描述任务的熟练能力。然而，在黑盒蒸馏中，知识迁移完全依赖于数据集，因此能否获得足够大的数据集至关重要。因此，这些方法 [54, 103, 144, 154] 的共同做法是创建一个由指令、输入和输出组成的全面数据集。这个数据集使学生模型能够从教师模型那里获得丰富的知识。

具体而言，Wang 等人 [144] 提出了自指令（self-instruction，即 Self-Instruct），这是一种半自动过程，利用来自模型自身的指示信号来改进语言模型的指令。该过程从一个有限的人工编写任务种子集（例如我们（原文如此）研究中使用的 175 个任务）开始，以指导整个生成过程。首先，提示模型利用这组初始指令生成更广泛的任务描述。接着，对于新生成的指令集，该框架创建可在将来用于监督式指令微调的输入-输出实例。最后，在把剩余有效任务加入任务池之前，采用各种启发式方法自动过滤掉低质量或重复的指令。这一迭代过程可以重复多次，直到获得大量任务。该方法影响了后续研究，促使 Alpaca [127]、Vicuna [24] 和 GPT4All [6] 等 13B 开源模型沿用这一范式进行调整。在这些思路的基础上，Peng 等人 [103] 探索了使用 GPT-4 生成指令遵循数据来微调 LLM。他们整理了一个包含 52,000 条中英文指令遵循样例的数据集，以及由 GPT-4 生成的反馈数据集。利用这些数据集，他们微调了两个学生模型：LLaMA-GPT4 和 LLaMA-GPT4-CN。此外，他们还开发了一个反馈模型来评估模型回答的质量。Wu 等人 [154] 精心编制了一个包含 258 万条指令的数据集，确保覆盖多样的主题。这些指令被用作输入，借助 GPT-3.5 Turbo 生成回答。他们在 LaMini-LM 名下微调了一系列模型，包括编码器-解码器和仅解码器两种架构。对 LaMini-LM 模型性能的评估既在 15 个基准上使用了自动指标，也进行了人工评估。结果表明，所提出的 LaMini-LM 模型虽然规模只有十分之一，却取得了与有竞争力的基线相当的性能。

然而，现有方法主要集中于单向知识蒸馏，即让学生模型的回答与教师模型的回答对齐来生成指令，而没有引入“反馈”机制。为了解决这一局限，Jiang 等人 [54] 提出了一个创新的对抗蒸馏框架，包含三个阶段：模仿、判别和生成。借助 LLM 的适应性，该框架激励教师模型识别出“有挑战性”的指令，并为学生模型生成新的指令，从而增强知识迁移的效果。该方法仅用 70,000 个训练样本就实现了可与 ChatGPT 相媲美的开放式生成能力，在零样本推理任务 BBH 和 AGIEval 上分别比传统最先进的指令微调模型（如 Vicuna-13B）高出 55.4% 和 16.7%。为了提供针对特定任务的指导，Chen 等人 [18] 提出了一个代码生成指令微调数据集，并开发了一种多轮个性化蒸馏方法。该方法让学生模型先尝试独立解决任务，再由教师根据执行反馈提供自适应的改进，以提升学生的表现。与把教师的先验知识直接传授给学生的传统知识迁移方法不同，个性化改进通过只从错误样例中学习并迭代改进解答，提供了个性化的学习体验。与此同时，UniversalNER [169] 对命名实体识别任务进行了广泛研究。与上述旨在增加指令多样性的方法不同，UniversalNER 侧重于增加输入的多样性，以增强模型在各个领域的泛化能力。

3.5 黑盒 KD 的鲁棒性评估（Robustness Evaluation of Black-box KD）

受 [47] 工作的启发，我们从鲁棒性的角度对基于 CoT 的逐步蒸馏算法进行了统一评估。由于 PaLM 540B 模型是闭源的，我们沿用了 [47] 中的实验设置，使用其已生成的 CoT 解释来微调学生模型。实验结果见表 6–8。对于 1.2 亿和 3.4 亿参数的 GPT-2 模型，使用来自 ANLI 和 e-SNLI 数据集的解释进行蒸馏效果更好。然而，随着模型规模增大，这两个数据集的解释效力减弱，在 OPT 模型中也观察到类似趋势。对于各种规模的 OPT 模型，由 ANLI 和 e-SNLI 生成的解释的蒸馏效果都不理想。这表明常识数据（CQA）和数学数据（SVAMP）更有利于 OPT 模型的 CoT 蒸馏。无论是 LLaMA 还是 OPT，在 Flipkart 和 DDXPlus 上，用 CQA 和 SVAMP 进行 CoT 蒸馏都优于用另外两个数据集进行的蒸馏。这表明对数学能力和常识知识的蒸馏增强了模型泛化到分布外数据的能力。

> 译者注：表 6–8 中“方法”一列的 ANLI、CQA、e-SNLI、SVAMP 表示用该数据集上的 CoT 解释进行逐步蒸馏得到的学生模型；粗体与 * 标记按原表保留（原表标题未重复说明，含义应与表 2 相同）。

表 6：GPT-2 的评估结果。（SST-2 至 ANLI 为对抗鲁棒性 ASR↓；Flipkart、DDXPlus 为分布外鲁棒性 F1↑）

参数量（Params）	方法（Method）	SST-2	QQP	MNLI	QNLI	RTE	MNLI-MM	ANLI	Flipkart	DDXPlus
1.5B	教师（Teacher）	62.84	94.87	76.03	75.68	56.79	74.07	89.42	10.72	0
120M	ANLI	**56.76***	74.36	73.55	**57.43***	**45.68***	**64.81***	92.75	**25.32***	0
120M	CQA	85.81	96.15	95.87	96.62	98.77	93.83	94.17	8.56	0
120M	e-SNLI	99.32	**66.67***	**65.29***	60.81	58.02	71.60	**68.50***	1.38	0
120M	SVAMP	80.41	93.59	85.95	90.54	93.83	82.72	95.42	3.98	**1.02***
340M	ANLI	58.78	**50.00***	**78.51**	**61.49***	46.91	68.52	87.08	27.39	0
340M	CQA	52.70	87.18	88.43	94.59	97.53	91.36	94.08	**31.82***	0
340M	e-SNLI	99.32	71.79	80.99	65.54	**41.98***	**66.67***	**72.83***	4.61	0
340M	SVAMP	**50.00***	69.23	80.17	77.03	64.20	77.78	76.08	25.60	0
760M	ANLI	89.19	89.74	88.43	75.68	93.83	86.42	**92.83**	6.48	0
760M	CQA	**54.73***	**83.33***	90.08	75.00	**83.95**	94.44	98.83	**33.03***	0
760M	e-SNLI	100	100	100	100	100	100	100	1.38	0
760M	SVAMP	64.19	70.51	**87.60**	**70.27***	85.19	**85.19**	96.75	9.84	0

表 7：OPT 的评估结果。

参数量（Params）	方法（Method）	SST-2	QQP	MNLI	QNLI	RTE	MNLI-MM	ANLI	Flipkart	DDXPlus
13B	教师（Teacher）	68.24	80.77	74.38	50.68	56.79	69.75	72.33	32.04	0
1.3B	ANLI	100	100	100	100	100	100	100	0	0
1.3B	CQA	50.00	**85.90**	**57.85***	**66.89**	**43.21***	**64.81***	**96.00**	36.00	0
1.3B	e-SNLI	75.00	93.59	81.82	83.78	67.90	79.63	97.33	2.93	0
1.3B	SVAMP	**49.32***	92.31	78.51	78.38	53.09	75.93	99.33	**52.44***	**0.85***
2.7B	ANLI	100	100	100	100	100	97.53	98.50	0	0
2.7B	CQA	**50.68***	87.18	80.99	75.00	**38.27***	**61.11***	81.92	31.15	**1.33***
2.7B	e-SNLI	87.84	79.49	90.91	87.84	86.42	86.42	96.50	3.48	0
2.7B	SVAMP	51.35	**65.38***	**68.60***	**61.49**	66.67	64.20	**70.33***	**43.51***	0.08
6.7B	ANLI	100	100	99.17	100	100	100	99.83	0	0
6.7B	CQA	**52.03***	98.72	85.12	**83.78**	**64.20**	93.83	97.08	**44.62***	0
6.7B	e-SNLI	100	**67.95***	91.74	84.46	70.37	85.80	94.75	0.87	0
6.7B	SVAMP	58.78	84.62	**76.03**	94.59	86.42	**72.84**	**82.83**	31.77	**0.15***

表 8：LLaMA 与 LLaMA2 的评估结果。

参数量（Params）	方法（Method）	SST-2	QQP	MNLI	QNLI	RTE	MNLI-MM	ANLI	Flipkart	DDXPlus
13B（LLaMA 教师）	教师（Teacher）	50.68	69.23	62.81	58.78	46.91	77.78	69.83	49.16	5.74
LLaMA_7B	ANLI	**41.22***	60.26	**53.72***	**47.97***	54.32	**61.11***	71.08	2.16	4.80
LLaMA_7B	CQA	46.62	**46.15***	66.12	53.38	**46.91**	64.81	77.42	**41.37**	**8.33***
LLaMA_7B	e-SNLI	49.32	84.62	57.85	58.11	61.73	63.58	**70.33**	1.38	1.46
LLaMA_7B	SVAMP	46.62	74.36	72.73	52.70	61.73	67.90	77.75	32.44	1.46
13B（LLaMA2 教师）	教师（Teacher）	53.38	50.00	71.07	45.95	50.62	62.35	71.83	33.76	18.92
LLaMA2_7B	ANLI	64.19	61.54	**61.98***	52.70	56.79	61.11	**62.08***	23.88	1.02
LLaMA2_7B	CQA	**44.59***	48.72	66.94	50.00	43.21	66.05	66.50	**35.10***	8.19
LLaMA2_7B	e-SNLI	61.49	**44.87***	74.38	**40.54***	**41.98***	**58.64***	67.33	5.48	4.71
LLaMA2_7B	SVAMP	58.11	53.85	78.51	56.08	61.73	69.14	70.42	27.01	**11.67**

3.6 关于黑盒 KD 的讨论（Discussion on Black-box KD）

基于黑盒的 KD 方法通常由 LLM 生成解释或指令对来微调学生模型。在这种方法中，只有教师模型生成数据，只有学生模型参与训练，因此显存效率高。然而，当前大多数方法依赖闭源的教师模型，生成额外数据的成本可能很高。此外，许多方法没有开源其数据生成技术，或者涉及闭源的生成数据，这给公平评估这些基于黑盒的蒸馏算法带来了挑战。

3.7 其他（Others）

随着大语言模型的显著进步，它们的固有局限在于无法理解视觉信息，因为它们主要是为处理离散文本而设计的。因此，研究者越来越多地探索如何把语言模型的能力迁移到多模态领域，在其中融合文本和图像数据，以支持更广泛的任务 [32, 36, 158]。从预训练多模态模型中提取知识，以提升紧凑型多模态语言模型的性能和泛化能力，已成为该领域关注的焦点。

3.7.1 多模态大语言模型（Multi-Modal Large Language Models） 多模态大模型的知识蒸馏仍处于起步阶段，主要侧重于改进指令遵循能力。Li 等人 [70] 率先提出了一个包含两个阶段的多模态大模型知识蒸馏新框架。第一阶段是多模态预训练，通过一个投影层对齐多模态特征。第二阶段称为多模态竞争蒸馏（multimodal competitive distillation），它建立了一个双向反馈循环，包括：1）多模态指令调整，确保学生的回答与教师提供的多模态指令保持一致；2）多模态评估，识别有挑战性的多模态指令；3）多模态增强，即生成新指令并与原始图像结合，构建新的多模态指令数据集来训练学生模型。在 ScienceQA [80]、SEED-Bench [66] 和 LLaVA Test Set [78] 等数据集上的评估表明，CoMD 在推理任务和零样本设定下都超越了现有模型。Park 等人 [101] 通过从 LLM 中采样局部化的常识知识，开发了一个局部化视觉常识模型。用户可以指定区域作为输入，并由一个单独训练的评判模型（critic model）挑选高质量样例。零样本设定下的实证结果和人工评估表明，与简单地把生成的指代表达传给基线 LLM 相比，这种蒸馏方法产生了更准确的视觉-语言（VL）推理模型。类似地，Hu 等人 [49] 提出了用于视觉程序蒸馏的指令微调（Visual Program Distillation, VPD）。VPD 利用 LLM 的推理能力：采样多个候选程序，执行并验证它们，再把正确的程序转换为推理步骤的语言描述，用于视觉-语言模型（VLM）的蒸馏。大量实验表明，VPD 增强了 VLM 的计数、空间关系理解和组合推理能力，在 MMBench [79]、OK-VQA [84]、A-OKVQA [114]、TallyQA [1]、POPE [71] 和 Hateful Memes [62] 等具有挑战性的视觉任务上取得了最先进的性能。

表 9：LLM 蒸馏的应用。

模型	蒸馏场景	教师模型	压缩率	评估任务	与教师模型的比较
HuatuoGPT [162]	医疗健康	GPT-3.5_turbo	/	cMedQA2[164]/webMedQA[39]/HuatuoMed-26M[67]	25.18/39.20（150% 性能）
Chatdoctor [72]	医疗健康	GPT-3.5_turbo	/	HealthCareMagic100k[72]	42.5/84.1（100% 性能）
PMC-LLaMA [153]	医疗健康	ChatGPT	/	PubMedQA[58]/MedMCQA[99]/USMLE[57]	44.0/51.9/（157% 性能）
DARWIN [156]	教育	GPT-3_175B	25×	SciQ[150]/FAIR[113]	93.6/82.7（113% 性能）
WizardMath [81]	教育	ChatGPT	/	GSM8k[27]/MATH[42]	22.2/57.5（91% 性能）
K2 [29]	教育	LLaMA_7B	1750×	GeoBench[29]	34.6/24.6（141% 性能）
LawyerLLaMA [50]	法律	GPT-3.5_turbo	/	C3[121]/CMNLI[157]/SciQ[150]/PIQA[8]	

模型	蒸馏场景	教师模型	压缩率	评估任务	与教师模型的比较
ChatLaw [28]	法律	Ziya-LLaMA_13B	/	Legal Multiple-choice Questions[28]	/

4 应用（Applications）

在本节中，我们简要探讨 LLM 蒸馏在医疗健康、教育和法律等多个关键领域中的应用。

4.1 医疗健康（Healthcare）

医疗健康是一个与人类福祉密切相关的关键领域。自 ChatGPT 问世以来，许多工作都致力于在医学领域发挥 ChatGPT 和其他 LLM 的能力。例如，Zhang 等人 [162] 推出了 HuatuoGPT，这是一个专为医疗咨询设计的 LLM。通过从 ChatGPT 蒸馏数据，并借助监督微调融入来自医生的真实世界经验，HuatuoGPT 引入了一个奖励模型，旨在协同利用两类数据各自的优势。实证结果表明，HuatuoGPT 在医疗咨询中取得了最先进的性能，在基于 GPT-4 的多项评估指标（包括人工评估和医学基准数据集）上都优于 GPT-3.5_turbo。Li 等人 [72] 指出专门面向医学领域定制的 LLM 十分稀缺。他们以 LLaMA 作为开发和评估平台，探索了两种增强策略——模型微调和知识整合——来提升 LLM 作为医疗聊天机器人的效果。他们在一个包含 10 万条来自在线医疗咨询平台的医患对话（原文作 patient physiological dialogues）的数据集上微调对话模型，实验表明 Chatdoctor 模型在准确率和 F1 分数上都超过了 ChatGPT。此外，Wu 等人 [153] 推出了 PMC-LLaMA，它融合了 480 万篇生物医学学术论文和 3 万本医学教科书来注入以数据为中心的知识，并结合了针对特定领域指令的全面微调。PMC-LLaMA 的参数量仅为 13B，却表现出色，在多个公开医学问答基准上超过了 ChatGPT。

4.2 教育（Education）

教育是 LLM 展现出巨大潜力的另一个关键领域。当前研究表明，LLM 在物理和计算机科学等各类数学相关学科（原文如此）的标准化考试中，可以达到与学生相当的水平 [2]。Xie 等人 [156] 提出了 DARWIN，这是一个旨在通过加速和丰富发现过程的自动化来推动自然科学发展的框架。该方法包含科学指令生成（Scientific Instruction Generation, SIG）模型，整合了来自公开数据集和文献的结构化与非结构化科学知识。DARWIN 无需人工抽取或特定领域的知识图谱，就在多种科学任务上取得了最先进的性能。Luo 等人 [81] 提出了 WizardMath，它利用基于 Evol-Instruct 反馈的强化学习（RLEIF）技术来增强 LLaMA-2 [130] 的数学推理能力。该方法使用数学专用的 Evol-Instruct 生成多样的数学指令数据，随后训练指令奖励模型（Instruction Reward Model, IRM）和过程监督奖励模型（Process Supervised Reward Model, PRM）[160]。IRM 评估演化指令的质量，而 PRM 则在求解过程的每一步提供反馈。在 GSM8k [27] 和 MATH [42] 两个数学推理基准上的大量实验表明，WizardMath 显著优于其他开源 LLM。此外，Deng 等人 [29] 推出了面向地球科学的 LLM K2，并建立了首个地球科学基准 GeoBench，用于评估该领域的 LLM。

4.3 法律（Law）

法律是一个富含专业知识的领域，近来已开始采用 LLM 处理各种法律任务，如法律文书分析 [9] 和法律文书生成 [25]。Huang 等人 [50] 通过精心设计的监督微调任务，把法律专业知识融入 LLaMA 的持续训练阶段。这些任务旨在向模型传授专业技能，同时缓解模型生成幻觉（原文作 illusions）的问题。为了增强训练，他们引入了一个检索模块，在模型生成回答之前先检索相关法条。类似地，Cui 等人 [28] 把法律专用数据整合进 LLaMA，打造出 ChatLaw。出于对从法律数据集中检索参考资料准确性的关注，他们开发了一种结合向量数据库检索和

关键词检索的混合方法。该方法通过实现一种自注意力机制来应对幻觉问题并提高准确率。这一机制增强了大模型纠正参考数据中错误的能力，从而提高了在法律语境下的连贯性和问题求解能力。

5 挑战与未来方向（Challenges and Future Directions）

5.1 统一的评估基准（Unified Evaluation Benchmark）

现有的知识蒸馏评估基准主要分为四类：1）通用语言理解评估（General Language Understanding Evaluation, GLUE）基准 [137]：该基准由九个句子级分类任务组成，包括语言可接受性 [148]、情感分析 [118]、文本相似度 [15]、蕴含检测 [31] 和自然语言推断 [107]。它常被用于评估以 BERT 为教师模型的蒸馏方法。2）MMLU 基准 [41]（原文写作 Multimodal Multitask Learning Understanding，通常指 Massive Multitask Language Understanding）：该基准是评估 LLM 多任务知识理解能力的通用评估工具。它涵盖数学、计算机科学、人文和社会科学等多个领域，任务难度从基础到高级不等。3）BIG Bench [119]：一项旨在构建全面评估基准、在多样任务上探索现有 LLM 能力的协作工作。它包含 204 项任务，涵盖语言学、儿童发展、数学、常识推理、生物学、物理学、社会偏见、软件开发等。4）HELM 基准 [76]（原文写作 Human-Evaluated Language Models, 通常指 Holistic Evaluation of Language Models）：这是一个由 16 个核心场景和 7 类指标组成的整体性评估基准。它整合了此前提出的多种评估基准，以全面评估 LLM 的性能。这些基准共同涵盖了主流 LLM 评估任务的广泛范围。此外，还有针对特定任务的专门评估基准，例如用于评估多语言知识运用的 TyDiQA [26] 和用于评估多语言数学推理的 MGSM [115]。随着大模型的不断发展，评估标准也在不断更新，为知识蒸馏制定统一的评估标准仍是一个很有前景的研究方向。

5.2 先进算法（Advanced Algorithms）

当前的方法主要旨在让学生模型具备特定能力。例如，符号知识蒸馏（symbolic knowledge distillation）[152] 利用 LLM 收集和过滤数据，提取高质量的常识图谱来训练常识模型。类似地，DISCO [23] 利用 LLM 获取反事实数据，然后用一个大型教师自然语言推断模型对其进行过滤，以提升学生在自然语言推理任务上的能力。随着开源 LLM 的不断发展，探索面向 LLM 的白盒蒸馏算法可能是整合多种能力的有效途径。此外，目前 MLLM 蒸馏的发展速度落后于 LLM。因此，研究更先进的 MLLM 蒸馏算法可以更有效地促进多种模态的整合。

5.3 可解释性（Interpretability）

Stanton 等人 [120] 探讨了知识蒸馏的可解释性，并引入匹配度（matching degree）的概念来增强其可靠性。他们的研究揭示了若干重要见解：1）学生模型的泛化性能与匹配度之间的关系并不总是一致的。除自蒸馏外，泛化性能最好的模型并不总是表现出最高的保真度（fidelity）。2）学生模型的保真度与蒸馏过程的校准（calibration）之间存在显著相关性。虽然最忠实的学生模型未必总能取得最高准确率，但它始终表现出更好的校准。3）知识蒸馏过程中的优化很困难，导致保真度较低。同样，在大语言模型时代，知识蒸馏也面临类似的困难。例如，当前方法难以阐明 CoT 蒸馏是如何把 CoT 能力传授给学生语言模型的，也难以确定指令微调所需的数据量。因此，把可解释性融入这一过程对于推进 LLM 知识蒸馏至关重要。这种融合不仅有助于评估模型蒸馏，还能增强模型在生产环境中的可靠性和可预测性。

6 结论（Conclusion）

在本综述中，我们从方法、评估和应用三个角度系统地研究了知识蒸馏算法。与较小模型相比，较大模型的蒸馏面临更多挑战。尽管现有算法为应对这些挑战付出了相当大的努力，但许多算法仍然依赖最初为压缩较小模

型而定制的框架，压缩大模型的挑战依然存在。未来，在确保 LLM 的通用性和泛化能力的同时，必须更深入地研究开发更高效、更有效的压缩算法。本综述旨在提供有价值的参考，阐明当前的研究格局，并倡导对这一关键主题的持续探索，以便在师生框架内有效地设计、学习和应用各种蒸馏目标。

译者注：原文未设单独的“致谢（Acknowledgments）”部分，故本译本无致谢一节。

参考文献（References）

以下参考文献按原文编号保留英文原文（共 170 条，由 PDF 文本自动拼接换行，个别条目的排版断字可能与原 PDF 略有差异）。

- [1] Manoj Acharya, Kushal Kafle, and Christopher Kanan. 2019. TallyQA: answering complex counting questions. In Proceedings of the Thirty-Third AAAI Conference on Artificial Intelligence and Thirty-First Innovative Applications of Artificial Intelligence Conference and Ninth AAAI Symposium on Educational Advances in Artificial Intelligence. 8076–8084.
- [2] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. 2023. Gpt-4 technical report. arXiv preprint arXiv:2303.08774 (2023).
- [3] Rishabh Agarwal, Nino Vieillard, Yongchao Zhou, Piotr Stanczyk, Sabela Ramos, Matthieu Geist, and Olivier Bachem. 2023. Generalized knowledge distillation for auto-regressive language models. arXiv preprint arXiv:2306.13649 (2023).
- [4] Abdolmaged Alkhulaifi, Fahad Alsahli, and Irfan Ahmad. 2021. Knowledge distillation in deep learning and its applications. PeerJ Computer Science 7 (2021), e474.
- [5] Aida Amini, Saadia Gabriel, Shanchuan Lin, Rik Koncel-Kedziorski, Yejin Choi, and Hannaneh Hajishirzi. 2019. MathQA: Towards Interpretable Math Word Problem Solving with Operation-Based Formalisms. In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). 2357–2367.
- [6] Yuvanesh Anand, Zach Nussbaum, Brandon Duderstadt, Benjamin Schmidt, and Andriy Mulyar. 2023. Gpt4all: Training an assistant-style chatbot with large scale data distillation from gpt-3.5-turbo. GitHub (2023).
- [7] Jinze Bai, Shuai Bai, Yunfei Chu, Zeyu Cui, Kai Dang, Xiaodong Deng, Yang Fan, Wenbin Ge, Yu Han, Fei Huang, et al. 2023. Qwen technical report. arXiv preprint arXiv:2309.16609 (2023).
- [8] Yonatan Bisk, Rowan Zellers, Jianfeng Gao, Yejin Choi, et al. 2020. PIQA: Reasoning about Physical Commonsense in Natural Language. In Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 34. 7432–7439.
- [9] Andrew Blair-Stanek, Nils Holzenberger, and Benjamin Van Durme. 2023. Can GPT-3 Perform Statutory Reasoning?. In Proceedings of the Nineteenth International Conference on Artificial Intelligence and Law (ICAIL ’23). 22–31.
- [10] Ondřej Bojar, Christian Buck, Christian Federmann, Barry Haddow, Philipp Koehn, Johannes Leveling, Christof Monz, Pavel Pecina, Matt Post, Herve Saint-Amand, et al. 2014. Findings of the 2014 workshop on statistical machine translation. In Proceedings of the ninth workshop on statistical machine translation. 12–58.
- [11] Ondrej Bojar, Rajen Chatterjee, Christian Federmann, Yvette Graham, Barry Haddow, Matthias Huck, Antonio Jimeno Yepes, Philipp Koehn, Varvara Logacheva, Christof Monz, et al. 2016. Findings of the 2016 conference on machine translation (wmt16). In First conference on machine translation. Association for Computational Linguistics, 131–198.

- [12] Tom B Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. 2020. Language models are few-shot learners. In Proceedings of the 34th International Conference on Neural Information Processing Systems. 1877–1901.
- [13] Nitay Calderon, Subhabrata Mukherjee, Roi Reichart, and Amir Kantor. 2023. A Systematic Study of Knowledge Distillation for Natural Language Generation with Pseudo-Target Training. In Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 14632–14659.
- [14] Oana-Maria Camburu, Tim Rocktäschel, Thomas Lukasiewicz, and Phil Blunsom. 2018. e-SNLI: natural language inference with natural language explanations. In Proceedings of the 32nd International Conference on Neural Information Processing Systems. 9560–9572.
- [15] Daniel Cer, Mona Diab, Eneko Agirre, Iñigo Lopez-Gazpio, and Lucia Specia. 2017. SemEval-2017 Task 1: Semantic Textual Similarity Multilingual and Crosslingual Focused Evaluation. In Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2017). 1–14.
- [16] Hyungjoo Chae, Yongho Song, Kai Ong, Taeyoon Kwon, Minjin Kim, Youngjae Yu, Dongha Lee, Dongyeop Kang, and Jinyoung Yeo. 2023. Dialogue Chain-of-Thought Distillation for Commonsense-aware Conversational Agents. In Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 5606–5632.
- [17] Yupeng Chang, Xu Wang, Jindong Wang, Yuan Wu, Linyi Yang, Kaijie Zhu, Hao Chen, Xiaoyuan Yi, Cunxiang Wang, Yidong Wang, et al. 2024. A survey on evaluation of large language models. ACM Transactions on Intelligent Systems and Technology (2024).
- [18] Hailin Chen, Amrita Saha, Steven Hoi, and Shafiq Joty. 2023. Personalized Distillation: Empowering Open-Sourced LLMs with Adaptive Learning for Code Generation. In Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 6737–6749.
- [19] Hongzhan Chen, Siyue Wu, Xiaojun Quan, Rui Wang, Ming Yan, and Ji Zhang. 2023. MCC-KD: Multi-CoT Consistent Knowledge Distillation. In Findings of the Association for Computational Linguistics: EMNLP 2023. 6805–6820.
- [20] Liqun Chen, Shuyang Dai, Yunchen Pu, Erjin Zhou, Chunyuan Li, Qinliang Su, Changyou Chen, and Lawrence Carin. 2018. Symmetric variational autoencoder and connections to adversarial learning. In International Conference on Artificial Intelligence and Statistics. PMLR, 661–669.
- [21] Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. 2021. Evaluating large language models trained on code. arXiv preprint arXiv:2107.03374 (2021).
- [22] Yanda Chen, Ruiqi Zhong, Sheng Zha, George Karypis, and He He. 2022. Meta-learning via Language Model In-context Tuning. In Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 719–730.
- [23] Zeming Chen, Qiyue Gao, Kyle Richardson, Antoine Bosselut, and Ashish Sabharwal. 2022. DISCO: Distilling Phrasal Counterfactuals with Large Language Models. arXiv preprint arXiv:2212.10534 (2022).
- [24] Wei-Lin Chiang, Zhuohan Li, Zi Lin, Ying Sheng, Zhanghao Wu, Hao Zhang, Lianmin Zheng, Siyuan Zhuang, Yonghao Zhuang, Joseph E Gonzalez, et al. 2023. Vicuna: An open-source chatbot impressing gpt-4 with 90%* chatgpt quality. (2023).
- [25] Jonathan H Choi, Kristin E Hickman, Amy B Monahan, and Daniel Schwarcz. 2021. ChatGPT goes to law school. J. Legal Educ. 71 (2021), 387.
- [26] Jonathan H Clark, Eunsol Choi, Michael Collins, Dan Garrette, Tom Kwiatkowski, Vitaly Nikolaev, and Jennimaria Palomaki. 2020. TyDi QA: A Benchmark for Information-Seeking Question Answering in Typologically Diverse Languages. Transactions of the Association for Computational

Linguistics 8 (2020), 454–470.
- [27] Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, et al. 2021. Training verifiers to solve math word problems. arXiv preprint arXiv:2110.14168 (2021).
- [28] Jiaxi Cui, Zongjian Li, Yang Yan, Bohua Chen, and Li Yuan. 2023. Chatlaw: Open-source legal large language model with integrated external knowledge bases. arXiv preprint arXiv:2306.16092 (2023).
- [29] Cheng Deng, Tianhang Zhang, Zhongmou He, Yi Xu, Qiyuan Chen, Yuanyuan Shi, Luoyi Fu, Weinan Zhang, Xinbing Wang, Chenghu Zhou, et al. 2023. K2: A foundation language model for geoscience knowledge understanding and utilization. arXiv preprint arXiv:2306.05064 (2023).
- [30] Lei Deng, Guoqi Li, Song Han, Luping Shi, and Yuan Xie. 2020. Model compression and hardware acceleration for neural networks: A comprehensive survey. Proc. IEEE 108, 4 (2020), 485–532.
- [31] William B Dolan and Chris Brockett. 2005. Automatically Constructing a Corpus of Sentential Paraphrases. In Proceedings of the Third International Workshop on Paraphrasing (IWP2005).
- [32] Danny Driess, Fei Xia, Mehdi SM Sajjadi, Corey Lynch, Aakanksha Chowdhery, Brian Ichter, Ayzaan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, et al. 2023. Palm-e: An embodied multimodal language model. arXiv preprint arXiv:2303.03378 (2023).
- [33] Dheeru Dua, Yizhong Wang, Pradeep Dasigi, Gabriel Stanovsky, Sameer Singh, and Matt Gardner. 2019. DROP: A Reading Comprehension Benchmark Requiring Discrete Reasoning Over Paragraphs. In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). 2368–2378.
- [34] Yao Fu, Hao Peng, Litu Ou, Ashish Sabharwal, and Tushar Khot. 2023. Specializing Smaller Language Models towards Multi-Step Reasoning. arXiv preprint arXiv:2301.12726 (2023).
- [35] Mor Geva, Daniel Khashabi, Elad Segal, Tushar Khot, Dan Roth, and Jonathan Berant. 2021. Did Aristotle Use a Laptop? A Question Answering Benchmark with Implicit Reasoning Strategies. Transactions of the Association for Computational Linguistics 9 (2021), 346–361.
- [36] Tao Gong, Chengqi Lyu, Shilong Zhang, Yudong Wang, Miao Zheng, Qian Zhao, Kuikun Liu, Wenwei Zhang, Ping Luo, and Kai Chen. 2023. Multimodal-gpt: A vision and language model for dialogue with humans. arXiv preprint arXiv:2305.04790 (2023).
- [37] Jianping Gou, Baosheng Yu, Stephen J Maybank, and Dacheng Tao. 2021. Knowledge Distillation: A Survey. International Journal of Computer Vision 129, 6 (2021), 1789–1819.
- [38] Yuxian Gu, Li Dong, Furu Wei, and Minlie Huang. 2023. MiniLLM: Knowledge distillation of large language models. In The Twelfth International Conference on Learning Representations.
- [39] Junqing He, Mingming Fu, and Manshu Tu. 2019. Applying deep matching networks to Chinese medical question answering: a study and a dataset. BMC medical informatics and decision making 19, 2 (2019), 91–100.
- [40] Yihui He, Ji Lin, Zhijian Liu, Hanrui Wang, Li-Jia Li, and Song Han. 2018. Amc: Automl for model compression and acceleration on mobile devices. In Proceedings of the European conference on computer vision (ECCV). 784–800.
- [41] Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt. 2020. Measuring Massive Multitask Language Understanding. In International Conference on Learning Representations.
- [42] Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. 2021. Measuring mathematical problem solving with the math dataset. arXiv preprint arXiv:2103.03874 (2021).

- [43] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. 2015. Distilling the knowledge in a neural network. arXiv preprint arXiv:1503.02531 (2015).
- [44] Namgyu Ho, Laura Schmid, and Se-Young Yun. 2022. Large language models are reasoning teachers. arXiv preprint arXiv:2212.10071 (2022).
- [45] Or Honovich, Thomas Scialom, Omer Levy, and Timo Schick. 2022. Unnatural instructions: Tuning language models with (almost) no human labor. arXiv preprint arXiv:2212.09689 (2022).
- [46] Lu Hou, Zhiqi Huang, Lifeng Shang, Xin Jiang, Xiao Chen, and Qun Liu. 2020. DynaBERT: dynamic BERT with adaptive width and depth. In Proceedings of the 34th International Conference on Neural Information Processing Systems. 9782–9793.
- [47] Cheng-Yu Hsieh, Chun-Liang Li, Chih-Kuan Yeh, Hootan Nakhost, Yasuhisa Fujii, Alexander Ratner, Ranjay Krishna, Chen-Yu Lee, and Tomas Pfister. 2023. Distilling step-by-step! outperforming larger language models with less training data and smaller model sizes. arXiv preprint arXiv:2305.02301 (2023).
- [48] Chengming Hu, Xuan Li, Dan Liu, Haolun Wu, Xi Chen, Ju Wang, and Xue Liu. 2023. Teacher-student architecture for knowledge distillation: A survey. arXiv preprint arXiv:2308.04268 (2023).
- [49] Yushi Hu, Otilia Stretcu, Chun-Ta Lu, Krishnamurthy Viswanathan, Kenji Hata, Enming Luo, Ranjay Krishna, and Ariel Fuxman. 2023. Visual Program Distillation: Distilling Tools and Programmatic Reasoning into Vision-Language Models. arXiv preprint arXiv:2312.03052 (2023).
- [50] Quzhe Huang, Mingxu Tao, Zhenwei An, Chen Zhang, Cong Jiang, Zhibin Chen, Zirui Wu, and Yansong Feng. 2023. Lawyer LLaMA Technical Report. arXiv preprint arXiv:2305.15062 (2023).
- [51] Tianyu Huang, Weisheng Dong, Fangfang Wu, Xin Li, and Guangming Shi. 2023. Uncertainty-Driven Knowledge Distillation for Language Model Compression. IEEE/ACM Trans. Audio, Speech and Lang. Proc. (2023), 2850–2858.
- [52] Yukun Huang, Yanda Chen, Zhou Yu, and Kathleen McKeown. 2022. In-context Learning Distillation: Transferring Few-shot Learning Ability of Pre-trained Language Models. arXiv preprint arXiv:2212.10670 (2022).
- [53] Ferenc Huszár. 2015. How (not) to train your generative model: Scheduled sampling, likelihood, adversary? arXiv preprint arXiv:1511.05101 (2015).
- [54] Yuxin Jiang, Chunkit Chan, Mingyang Chen, and Wei Wang. 2023. Lion: Adversarial distillation of closed-source large language model. arXiv preprint arXiv:2305.12870 (2023).
- [55] Xiaoqi Jiao, Yichun Yin, Lifeng Shang, Xin Jiang, Xiao Chen, Linlin Li, Fang Wang, and Qun Liu. 2020. TinyBERT: Distilling BERT for Natural Language Understanding. In Findings of the Association for Computational Linguistics: EMNLP 2020. 4163–4174.
- [56] Zhanming Jie and Wei Lu. 2023. Leveraging training data in few-shot prompting for numerical reasoning. arXiv preprint arXiv:2305.18170 (2023).
- [57] Di Jin, Eileen Pan, Nassim Oufattole, Wei-Hung Weng, Hanyi Fang, and Peter Szolovits. 2021. What disease does this patient have? a large-scale open domain question answering dataset from medical exams. Applied Sciences 11, 14 (2021), 6421.
- [58] Qiao Jin, Bhuwan Dhingra, Zhengping Liu, William Cohen, and Xinghua Lu. 2019. PubMedQA: A Dataset for Biomedical Research Question Answering. In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2567–2577.
- [59] Minki Kang, Seanie Lee, Jinheon Baek, Kenji Kawaguchi, and Sung Ju Hwang. 2024. Knowledge-augmented reasoning distillation for small language models in knowledge-intensive tasks. In Advances in Neural Information Processing Systems, Vol. 36.
- [60] Jacob Devlin Ming-Wei Chang Kenton and Lee Kristina Toutanova. 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In Proceedings of NAACL-HLT.

4171–4186.
- [61] Tushar Khot, Peter Clark, Michal Guerquin, Peter Jansen, and Ashish Sabharwal. 2020. QASC: A Dataset for Question Answering via Sentence Composition. In Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 34. 8082–8090.
- [62] Douwe Kiela, Hamed Firooz, Aravind Mohan, Vedanuj Goswami, Amanpreet Singh, Pratik Ringshia, and Davide Testuggine. 2020. The hateful memes challenge: detecting hate speech in multimodal memes. In Proceedings of the 34th International Conference on Neural Information Processing Systems. 2611–2624.
- [63] Yoon Kim and Alexander M Rush. 2016. Sequence-Level Knowledge Distillation. In Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing. 1317–1327.
- [64] Hayeon Lee, Rui Hou, Jongpil Kim, Davis Liang, Sung Ju Hwang, and Alexander Min. 2023. A Study on Knowledge Distillation from Weak Teacher for Scaling Up Pre-trained Language Models. In Findings of the Association for Computational Linguistics: ACL 2023. 11239–11246.
- [65] Hyoje Lee, Yeachan Park, Hyun Seo, and Myungjoo Kang. 2023. Self-knowledge distillation via dropout. Computer Vision and Image Understanding 233 (2023), 103720.
- [66] Bohao Li, Rui Wang, Guangzhi Wang, Yuying Ge, Yixiao Ge, and Ying Shan. 2023. Seed-bench: Benchmarking multimodal llms with generative comprehension. arXiv preprint arXiv:2307.16125 (2023).
- [67] Jianquan Li, Xidong Wang, Xiangbo Wu, Zhiyi Zhang, Xiaolong Xu, Jie Fu, Prayag Tiwari, Xiang Wan, and Benyou Wang. 2023. Huatuo-26M, a Large-scale Chinese Medical QA Dataset. arXiv preprint arXiv:2305.01526 (2023).
- [68] Liunian Harold Li, Jack Hessel, Youngjae Yu, Xiang Ren, Kai-Wei Chang, and Yejin Choi. 2023. Symbolic Chain-ofThought Distillation: Small Models Can Also" Think" Step-by-Step. arXiv preprint arXiv:2306.14050 (2023).
- [69] Shiyang Li, Jianshu Chen, Yelong Shen, Zhiyu Chen, Xinlu Zhang, Zekun Li, Hong Wang, Jing Qian, Baolin Peng, Yi Mao, et al. 2022. Explanations from large language models make small reasoners better. arXiv preprint arXiv:2210.06726 (2022).
- [70] Xinwei Li, Li Lin, Shuai Wang, and Chen Qian. 2023. Unlock the power: Competitive distillation for multi-modal large language models. arXiv preprint arXiv:2311.08213 (2023).
- [71] Yifan Li, Yifan Du, Kun Zhou, Jinpeng Wang, Wayne Xin Zhao, and Ji-Rong Wen. 2023. Evaluating object hallucination in large vision-language models. arXiv preprint arXiv:2305.10355 (2023).
- [72] Yunxiang Li, Zihan Li, Kai Zhang, Ruilong Dan, Steve Jiang, and You Zhang. 2023. ChatDoctor: A Medical Chat Model Fine-Tuned on a Large Language Model Meta-AI (LLaMA) Using Medical Domain Knowledge. Cureus 15, 6 (2023).
- [73] Chen Liang, Haoming Jiang, Zheng Li, Xianfeng Tang, Bin Yin, and Tuo Zhao. 2023. Homodistil: Homotopic task-agnostic distillation of pre-trained transformers. arXiv preprint arXiv:2302.09632 (2023).
- [74] Chen Liang, Simiao Zuo, Qingru Zhang, Pengcheng He, Weizhu Chen, and Tuo Zhao. 2023. Less is more: Task-aware layer-wise distillation for language model compression. In International Conference on Machine Learning. PMLR, 20852–20867.
- [75] Kevin J Liang, Weituo Hao, Dinghan Shen, Yufan Zhou, Weizhu Chen, Changyou Chen, and Lawrence Carin. 2020. MixKD: Towards Efficient Distillation of Large-scale Language Models. In International Conference on Learning Representations.
- [76] Percy Liang, Rishi Bommasani, Tony Lee, Dimitris Tsipras, Dilara Soylu, Michihiro Yasunaga, Yian Zhang, Deepak Narayanan, Yuhuai Wu, Ananya Kumar, et al. 2022. Holistic evaluation of language models. arXiv preprint arXiv:2211.09110 (2022).
- [77] Chin-Yew Lin. 2004. Rouge: A package for automatic evaluation of summaries. In Text summa-

rization branches out. 74–81.
- [78] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. 2024. Visual instruction tuning. In Advances in neural information processing systems, Vol. 36.
- [79] Yuan Liu, Haodong Duan, Yuanhan Zhang, Bo Li, Songyang Zhang, Wangbo Zhao, Yike Yuan, Jiaqi Wang, Conghui He, Ziwei Liu, et al. 2023. Mmbench: Is your multi-modal model an all-around player? arXiv preprint arXiv:2307.06281 (2023).
- [80] Pan Lu, Swaroop Mishra, Tanglin Xia, Liang Qiu, Kai-Wei Chang, Song-Chun Zhu, Oyvind Tafjord, Peter Clark, and Ashwin Kalyan. 2022. Learn to explain: Multimodal reasoning via thought chains for science question answering. In Advances in Neural Information Processing Systems, Vol. 35. 2507–2521.
- [81] Haipeng Luo, Qingfeng Sun, Can Xu, Pu Zhao, Jianguang Lou, Chongyang Tao, Xiubo Geng, Qingwei Lin, Shifeng Chen, and Dongmei Zhang. 2023. Wizardmath: Empowering mathematical reasoning for large language models via reinforced evol-instruct. arXiv preprint arXiv:2308.09583 (2023).
- [82] Andrew L. Maas, Raymond E. Daly, Peter T. Pham, Dan Huang, Andrew Y. Ng, and Christopher Potts. 2011. Learning Word Vectors for Sentiment Analysis. In Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies. 142–150.
- [83] Lucie Charlotte Magister, Jonathan Mallinson, Jakub Adamek, Eric Malmi, and Aliaksei Severyn. 2022. Teaching small language models to reason. arXiv preprint arXiv:2212.08410 (2022).
- [84] Kenneth Marino, Mohammad Rastegari, Ali Farhadi, and Roozbeh Mottaghi. 2019. Ok-vqa: A visual question answering benchmark requiring external knowledge. In Proceedings of the IEEE/cvf conference on computer vision and pattern recognition. 3195–3204.
- [85] Julian McAuley and Jure Leskovec. 2013. Hidden factors and hidden topics: understanding rating dimensions with review text (RecSys ’13). 165–172.
- [86] Shen-Yun Miao, Chao-Chun Liang, and Keh-Yih Su. 2020. A Diverse Corpus for Evaluating and Developing English Math Word Problem Solvers. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 975–984.
- [87] Todor Mihaylov, Peter Clark, Tushar Khot, and Ashish Sabharwal. 2018. Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering. In Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. 2381–2391.
- [88] Sewon Min, Mike Lewis, Luke Zettlemoyer, and Hannaneh Hajishirzi. 2022. MetaICL: Learning to Learn In Context. In Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2791–2809.
- [89] Sewon Min, Xinxi Lyu, Ari Holtzman, Mikel Artetxe, Mike Lewis, Hannaneh Hajishirzi, and Luke Zettlemoyer. 2022. Rethinking the Role of Demonstrations: What Makes In-Context Learning Work?. In Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. 11048–11064.
- [90] Seyed Iman Mirzadeh, Mehrdad Farajtabar, Ang Li, Nir Levine, Akihiro Matsukawa, and Hassan Ghasemzadeh. 2020. Improved knowledge distillation via teacher assistant. In Proceedings of the AAAI conference on artificial intelligence, Vol. 34. 5191–5198.
- [91] Subhabrata Mukherjee and Ahmed Hassan Awadallah. 2020. XtremeDistil: Multi-stage Distillation for Massive Multilingual Models. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2221–2234.
- [92] Linyong Nan, Dragomir Radev, Rui Zhang, Amrit Rau, Abhinand Sivaprasad, Chiachun Hsieh, Xiangru Tang, Aadit Vyas, Neha Verma, Pranav Krishna, et al. 2021. DART: Open-Domain Structured Data Record to Text Generation. In Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 432–447.

- [93] Shashi Narayan, Shay B Cohen, and Mirella Lapata. 2018. Don’t Give Me the Details, Just the Summary! Topic-Aware Convolutional Neural Networks for Extreme Summarization. In Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. 1797–1807.
- [94] Yixin Nie, Adina Williams, Emily Dinan, Mohit Bansal, Jason Weston, and Douwe Kiela. 2020. Adversarial NLI: A New Benchmark for Natural Language Understanding. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 4885–4901.
- [95] Yixin Nie, Adina Williams, Emily Dinan, Mohit Bansal, Jason Weston, and Douwe Kiela. 2020. Adversarial NLI: A New Benchmark for Natural Language Understanding. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics.
- [96] Sebastian Nowozin, Botond Cseke, and Ryota Tomioka. 2016. f-GAN: training generative neural samplers using variational divergence minimization. In Proceedings of the 30th International Conference on Neural Information Processing Systems. 271–279.
- [97] Yasumasa Onoe, Michael JQ Zhang, Eunsol Choi, and Greg Durrett. 2021. CREAK: A dataset for commonsense reasoning over entity knowledge. arXiv preprint arXiv:2109.01653 (2021).
- [98] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. 2022. Training language models to follow instructions with human feedback. In Advances in Neural Information Processing Systems, Vol. 35. 27730–27744.
- [99] Ankit Pal, Logesh Kumar Umapathi, and Malaikannan Sankarasubbu. 2022. Medmcqa: A large-scale multi-subject multi-choice dataset for medical domain question answering. In Conference on Health, Inference, and Learning. PMLR, 248–260.
- [100] Xiaoman Pan, Boliang Zhang, Jonathan May, Joel Nothman, Kevin Knight, and Heng Ji. 2017. Cross-lingual Name Tagging and Linking for 282 Languages. In Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 1946–1958.
- [101] Jae Sung Park, Jack Hessel, Khyathi Chandu, Paul Pu Liang, Ximing Lu, Peter West, Youngjae Yu, Qiuyuan Huang, Jianfeng Gao, Ali Farhadi, et al. 2023. Localized Symbolic Knowledge Distillation for Visual Commonsense Models. In Thirty-seventh Conference on Neural Information Processing Systems.
- [102] Arkil Patel, Satwik Bhattamishra, and Navin Goyal. 2021. Are NLP Models really able to Solve Simple Math Word Problems?. In Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2080–2094.
- [103] Baolin Peng, Chunyuan Li, Pengcheng He, Michel Galley, and Jianfeng Gao. 2023. Instruction tuning with gpt-4. arXiv preprint arXiv:2304.03277 (2023).
- [104] Matthew E Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, and Luke Zettlemoyer. 2018. Deep contextualized word representations. In Proceedings of NAACL-HLT. 2227–2237.
- [105] Fabio Petroni, Tim Rocktäschel, Sebastian Riedel, Patrick Lewis, Anton Bakhtin, Yuxiang Wu, and Alexander Miller. 2019. Language Models as Knowledge Bases?. In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2463–2473.
- [106] Pranav Rajpurkar, Robin Jia, and Percy Liang. 2018. Know What You Don’t Know: Unanswerable Questions for SQuAD. Cornell University - arXiv,Cornell University - arXiv (Jun 2018).
- [107] Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. 2016. SQuAD: 100,000+ Questions for Machine Comprehension of Text. In Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing. 2383–2392.
- [108] Laria Reynolds and Kyle McDonell. 2021. Prompt programming for large language models:

Beyond the few-shot paradigm. In Extended Abstracts of the 2021 CHI Conference on Human Factors in Computing Systems. 1–7.

- [109] Adriana Romero, Nicolas Ballas, Samira Ebrahimi Kahou, Antoine Chassang, Carlo Gatta, and Yoshua Bengio. 2014. Fitnets: Hints for thin deep nets. arXiv preprint arXiv:1412.6550 (2014).
- [110] Subhro Roy and Dan Roth. 2015. Solving General Arithmetic Word Problems. In Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. 1743–1752.
- [111] Victor Sanh, Lysandre Debut, Julien Chaumond, and Thomas Wolf. 2019. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv preprint arXiv:1910.01108 (2019).
- [112] Victor Sanh, Albert Webson, Colin Raffel, Stephen Bach, Lintang Sutawika, Zaid Alyafeai, Antoine Chaffin, Arnaud Stiegler, Arun Raja, Manan Dey, et al. 2021. Multitask Prompted Training Enables Zero-Shot Task Generalization. In International Conference on Learning Representations.
- [113] Matthias Scheffler, Martin Aeschlimann, Martin Albrecht, Tristan Bereau, Hans-Joachim Bungartz, Claudia Felser, Mark Greiner, Axel Groß, Christoph T Koch, Kurt Kremer, et al. 2022. FAIR data enabling new horizons for materials research. Nature 604, 7907 (2022), 635–642.
- [114] Dustin Schwenk, Apoorv Khandelwal, Christopher Clark, Kenneth Marino, and Roozbeh Mottaghi. 2022. A-okvqa: A benchmark for visual question answering using world knowledge. In European Conference on Computer Vision. Springer, 146–162.
- [115] Freda Shi, Mirac Suzgun, Markus Freitag, Xuezhi Wang, Suraj Srivats, Soroush Vosoughi, Hyung Won Chung, Yi Tay, Sebastian Ruder, Denny Zhou, et al. 2022. Language models are multilingual chain-of-thought reasoners. In The Eleventh International Conference on Learning Representations.
- [116] Kumar Shridhar, Alessandro Stolfo, and Mrinmaya Sachan. 2023. Distilling reasoning capabilities into smaller language models. In Findings of the Association for Computational Linguistics: ACL 2023. 7059–7073.
- [117] Richard Socher, John Bauer, Christopher D. Manning, and Andrew Y. Ng. 2013. Parsing with Compositional Vector Grammars. In Proceedings of the 51st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 455–465.
- [118] Richard Socher, Alex Perelygin, Jean Wu, Jason Chuang, Christopher D Manning, Andrew Y Ng, and Christopher Potts. 2013. Recursive deep models for semantic compositionality over a sentiment treebank. In Proceedings of the 2013 conference on empirical methods in natural language processing. 1631–1642.
- [119] Aarohi Srivastava, Abhinav Rastogi, Abhishek Rao, Abu Awal Md Shoeb, Abubakar Abid, Adam Fisch, Adam R Brown, Adam Santoro, Aditya Gupta, Adrià Garriga-Alonso, et al. 2023. Beyond the Imitation Game: Quantifying and extrapolating the capabilities of language models. Transactions on Machine Learning Research (2023).
- [120] Samuel Stanton, Pavel Izmailov, Polina Kirichenko, Alexander A Alemi, and Andrew G Wilson. 2021. Does knowledge distillation really work?. In Advances in Neural Information Processing Systems, Vol. 34. 6906–6919.
- [121] Kai Sun, Dian Yu, Dong Yu, and Claire Cardie. 2020. Investigating Prior Knowledge for Challenging Chinese Machine Reading Comprehension. Transactions of the Association for Computational Linguistics 8 (2020), 141–155.
- [122] Siqi Sun, Yu Cheng, Zhe Gan, and Jingjing Liu. 2019. Patient Knowledge Distillation for BERT Model Compression. In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 4323–4332.
- [123] Zhiqing Sun, Hongkun Yu, Xiaodan Song, Renjie Liu, Yiming Yang, and Denny Zhou. 2020. MobileBERT: a Compact Task-Agnostic BERT for Resource-Limited Devices. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2158–2170.

- [124] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. 2017. Axiomatic attribution for deep networks. In Proceedings of the 34th International Conference on Machine Learning - Volume 70 (Sydney, NSW, Australia) (ICML’17). 3319–3328.
- [125] Alon Talmor, Jonathan Herzig, Nicholas Lourie, and Jonathan Berant. 2019. CommonsenseQA: A Question Answering Challenge Targeting Commonsense Knowledge. In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). 4149–4158.
- [126] Raphael Tang, Yao Lu, Linqing Liu, Lili Mou, Olga Vechtomova, and Jimmy Lin. 2019. Distilling task-specific knowledge from bert into simple neural networks. arXiv preprint arXiv:1903.12136 (2019).
- [127] Rohan Taori, Ishaan Gulrajani, Tianyi Zhang, Yann Dubois, Xuechen Li, Carlos Guestrin, Percy Liang, and Tatsunori B. Hashimoto. 2023. Stanford Alpaca: An Instruction-following LLaMA model. GitHub repository (2023).
- [128] Arsene Fansi Tchango, Rishab Goel, Zhi Wen, Julien Martel, and Joumana Ghosn. 2022. DDXPlus: A New Dataset For Automatic Medical Diagnosis. In Thirty-sixth Conference on Neural Information Processing Systems Datasets and Benchmarks Track.
- [129] Xudong Tian, Zhizhong Zhang, Shaohui Lin, Yanyun Qu, Yuan Xie, and Lizhuang Ma. 2021. Farewell to mutual information: Variational distillation for cross-modal person re-identification. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 1522–1531.
- [130] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, et al. 2023. Llama 2: Open foundation and fine-tuned chat models. arXiv preprint arXiv:2307.09288 (2023).
- [131] Henry Tsai, Jason Riesa, Melvin Johnson, Naveen Arivazhagan, and Amelia Archer. 2019. Small and Practical BERT Models for Sequence Labeling. In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 3632–3636.
- [132] Lifu Tu, Richard Yuanzhe Pang, Sam Wiseman, and Kevin Gimpel. 2020. ENGINE: Energy-Based Inference Networks for Non-Autoregressive Machine Translation. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2819–2826.
- [133] Lewis Tunstall, Edward Beeching, Nathan Lambert, Nazneen Rajani, Kashif Rasul, Younes Belkada, Shengyi Huang, Leandro von Werra, Clémentine Fourrier, Nathan Habib, et al. 2023. Zephyr: Direct distillation of lm alignment. arXiv preprint arXiv:2310.16944 (2023).
- [134] Iulia Turc, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. Well-read students learn better: On the importance of pre-training compact models. arXiv preprint arXiv:1908.08962 (2019).
- [135] Nirali Vaghani and Mansi Thummar. [n. d.]. Flipkart product reviews with sentiment dataset, 2023. URL https://www. kaggle. com/dsv/4940809 ([n. d.]).
- [136] Somin Wadhwa, Silvio Amir, and Byron C Wallace. 2023. Revisiting relation extraction in the era of large language models. arXiv preprint arXiv:2305.05003 (2023).
- [137] Alex Wang, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel Bowman. 2018. GLUE: A Multi-Task Benchmark and Analysis Platform for Natural Language Understanding. In Proceedings of the 2018 EMNLP Workshop BlackboxNLP: Analyzing and Interpreting Neural Networks for NLP. 353–355.
- [138] Boxin Wang, Chejian Xu, Shuohang Wang, Zhe Gan, Yu Cheng, Jianfeng Gao, Ahmed Hassan Awadallah, and Bo Li. 2021. Adversarial GLUE: A Multi-Task Benchmark for Robustness Evaluation of Language Models. In Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2).

- [139] Jindong Wang, HU Xixu, Wenxin Hou, Hao Chen, Runkai Zheng, Yidong Wang, Linyi Yang, Wei Ye, Haojun Huang, Xiubo Geng, et al. 2023. On the Robustness of ChatGPT: An Adversarial and Out-of-distribution Perspective. In ICLR 2023 Workshop on Trustworthy and Reliable Large-Scale Machine Learning Models.
- [140] Liang Wang, Nan Yang, and Furu Wei. 2023. Learning to retrieve in-context examples for large language models. arXiv preprint arXiv:2307.07164 (2023).
- [141] Lin Wang and Kuk-Jin Yoon. 2021. Knowledge distillation and student-teacher learning for visual intelligence: A review and new outlooks. IEEE transactions on pattern analysis and machine intelligence 44, 6 (2021), 3048–3068.
- [142] Peifeng Wang, Zhengyang Wang, Zheng Li, Yifan Gao, Bing Yin, and Xiang Ren. 2023. SCOTT: Self-consistent chain-of-thought distillation. arXiv preprint arXiv:2305.01879 (2023).
- [143] Wenhui Wang, Furu Wei, Li Dong, Hangbo Bao, Nan Yang, and Ming Zhou. 2020. MINILM: deep self-attention distillation for task-agnostic compression of pre-trained transformers. In Proceedings of the 34th International Conference on Neural Information Processing Systems. 5776–5788.
- [144] Yizhong Wang, Yeganeh Kordi, Swaroop Mishra, Alisa Liu, Noah A Smith, Daniel Khashabi, and Hannaneh Hajishirzi. 2022. Self-instruct: Aligning language model with self generated instructions. arXiv preprint arXiv:2212.10560 (2022).
- [145] Yizhong Wang, Swaroop Mishra, Pegah Alipoormolabashi, Yeganeh Kordi, Amirreza Mirzaei, Anjana Arunkumar, Arjun Ashok, Arut Selvan Dhanasekaran, Atharva Naik, David Stap, et al. 2022. Benchmarking generalization via in-context instructions on 1,600+ language tasks. arXiv e-prints (2022), arXiv–2204.
- [146] Yidong Wang, Zhuohao Yu, Zhengran Zeng, Linyi Yang, Cunxiang Wang, Hao Chen, Chaoya Jiang, Rui Xie, Jindong Wang, Xing Xie, et al. 2023. PandaLM: An Automatic Evaluation Benchmark for LLM Instruction Tuning Optimization. arXiv preprint arXiv:2306.05087 (2023).
- [147] Zhaoyang Wang, Shaohan Huang, Yuxuan Liu, Jiahai Wang, Minghui Song, Zihan Zhang, Haizhen Huang, Furu Wei, Weiwei Deng, Feng Sun, et al. 2023. Democratizing Reasoning Ability: Tailored Learning from Large Language Model. In Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 1948–1966.
- [148] Alex Warstadt, Amanpreet Singh, and Samuel Bowman. 2019. Neural Network Acceptability Judgments. Transactions of the Association for Computational Linguistics 7 (2019), 625–641.
- [149] Jason Wei, Maarten Bosma, Vincent Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M Dai, and Quoc V Le. 2021. Finetuned Language Models are Zero-Shot Learners. In International Conference on Learning Representations.
- [150] Johannes Welbl, Nelson F Liu, and Matt Gardner. 2017. Crowdsourcing Multiple Choice Science Questions. In Proceedings of the 3rd Workshop on Noisy User-generated Text. 94–106.
- [151] Yuqiao Wen, Zichao Li, Wenyu Du, and Lili Mou. 2023. f-Divergence Minimization for Sequence-Level Knowledge Distillation. In Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 10817–10834.
- [152] Peter West, Chandra Bhagavatula, Jack Hessel, Jena Hwang, Liwei Jiang, Ronan Le Bras, Ximing Lu, Sean Welleck, and Yejin Choi. 2022. Symbolic Knowledge Distillation: from General Language Models to Commonsense Models. In Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 4602–4625.
- [153] Chaoyi Wu, Weixiong Lin, Xiaoman Zhang, Ya Zhang, Yanfeng Wang, and Weidi Xie. 2023. Pmc-llama: Towards building open-source language models for medicine. arXiv preprint arXiv:2305.10415 6 (2023).
- [154] Minghao Wu, Abdul Waheed, Chiyu Zhang, Muhammad Abdul-Mageed, and Alham Fikri Aji.

2023. Lamini-lm: A diverse herd of distilled models from large-scale instructions. arXiv preprint arXiv:2304.14402 (2023).

- [155] Siyue Wu, Hongzhan Chen, Xiaojun Quan, Qifan Wang, and Rui Wang. 2023. AD-KD: Attribution-Driven Knowledge Distillation for Language Model Compression. In Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers).
- [156] Tong Xie, Yuwei Wan, Wei Huang, Zhenyu Yin, Yixuan Liu, Shaozhou Wang, Qingyuan Linghu, Chunyu Kit, Clara Grazian, Wenjie Zhang, et al. 2023. Darwin series: Domain specific large language models for natural science. arXiv preprint arXiv:2308.13565 (2023).
- [157] Liang Xu, Hai Hu, Xuanwei Zhang, Lu Li, Chenjie Cao, Yudong Li, Yechen Xu, Kai Sun, Dian Yu, Cong Yu, et al. 2020. CLUE: A Chinese Language Understanding Evaluation Benchmark. In Proceedings of the 28th International Conference on Computational Linguistics. 4762–4772.
- [158] Zhengyuan Yang, Linjie Li, Jianfeng Wang, Kevin Lin, Ehsan Azarnasab, Faisal Ahmed, Zicheng Liu, Ce Liu, Michael Zeng, and Lijuan Wang. 2023. Mm-react: Prompting chatgpt for multimodal reasoning and action. arXiv preprint arXiv:2303.11381 (2023).
- [159] Qinyuan Ye, Bill Yuchen Lin, and Xiang Ren. 2021. CrossFit: A Few-shot Learning Challenge for Cross-task Generalization in NLP. In Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. 7163–7189.
- [160] Zheng Yuan, Hongyi Yuan, Chengpeng Li, Guanting Dong, Chuanqi Tan, and Chang Zhou. 2023. Scaling relationship on learning mathematical reasoning with large language models. arXiv preprint arXiv:2308.01825 (2023).
- [161] Chen Zhang, Dawei Song, Zheyu Ye, and Yan Gao. 2023. Towards the law of capacity gap in distilling language models. arXiv preprint arXiv:2311.07052 (2023).
- [162] Hongbo Zhang, Junying Chen, Feng Jiang, Fei Yu, Zhihong Chen, Jianquan Li, Guiming Chen, Xiangbo Wu, Zhiyi Zhang, Qingying Xiao, et al. 2023. HuatuoGPT, towards Taming Language Model to Be a Doctor. arXiv preprint arXiv:2305.15075 (2023).
- [163] Jianyi Zhang, Aashiq Muhamed, Aditya Anantharaman, Guoyin Wang, Changyou Chen, Kai Zhong, Qingjun Cui, Yi Xu, Belinda Zeng, Trishul Chilimbi, and Yiran Chen. 2023. ReAugKD: Retrieval-Augmented Knowledge Distillation For Pre-trained Language Models. In Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). 1128–1136.
- [164] Sheng Zhang, Xin Zhang, Hui Wang, Lixiang Guo, and Shanshan Liu. 2018. Multi-scale attentive interaction networks for chinese medical question answer selection. IEEE Access 6 (2018), 74061–74071.
- [165] Xiang Zhang, Junbo Zhao, and Yann LeCun. 2015. Character-level convolutional networks for text classification. In Proceedings of the 28th International Conference on Neural Information Processing Systems-Volume 1. 649–657.
- [166] Wayne Xin Zhao, Kun Zhou, Junyi Li, Tianyi Tang, Xiaolei Wang, Yupeng Hou, Yingqian Min, Beichen Zhang, Junjie Zhang, Zican Dong, et al. 2023. A survey of large language models. arXiv preprint arXiv:2303.18223 (2023).
- [167] Pei Zhou, Karthik Gopalakrishnan, Behnam Hedayatnia, Seokhwan Kim, Jay Pujara, Xiang Ren, Yang Liu, and Dilek Hakkani-Tur. 2021. Commonsense-Focused Dialogues for Response Generation: An Empirical Study. In Proceedings of the 22nd Annual Meeting of the Special Interest Group on Discourse and Dialogue. 121–132.
- [168] Wangchunshu Zhou, Canwen Xu, and Julian McAuley. 2022. BERT Learns to Teach: Knowledge Distillation with Meta Learning. In Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 7037–7049.
- [169] Wenxuan Zhou, Sheng Zhang, Yu Gu, Muhao Chen, and Hoifung Poon. 2023. Universalner:

Targeted distillation from large language models for open named entity recognition. arXiv preprint arXiv:2308.03279 (2023).

- [170] Xuekai Zhu, Biqing Qi, Kaiyan Zhang, Xingwei Long, and Bowen Zhou. 2023. PaD: Program-aided Distillation Specializes Large Models in Reasoning. arXiv preprint arXiv:2305.13888 (2023).

（原文末尾模板信息）收稿日期 2007 年 2 月 20 日；修回日期 2009 年 3 月 12 日；录用日期 2009 年 6 月 5 日。（译者注：此为 ACM 模板占位信息。）